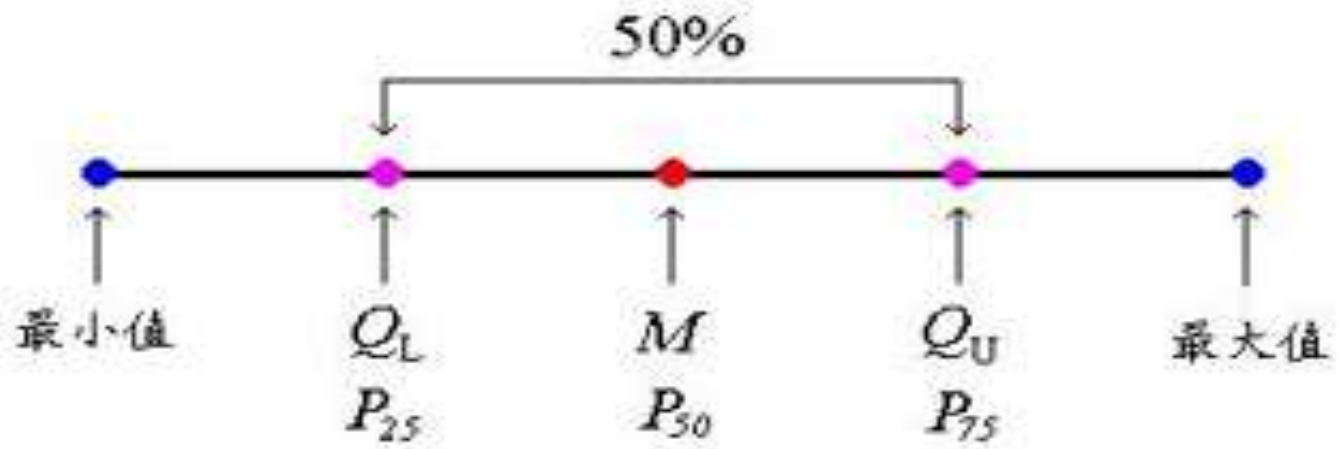
統計與多變量分析

Statistics & Multivariate Analysis

by

***Prof. Chih-Hsuan Wang* (王志軒)**

什麼是敘述統計？



離散型機率分配

Discrete Random Variables

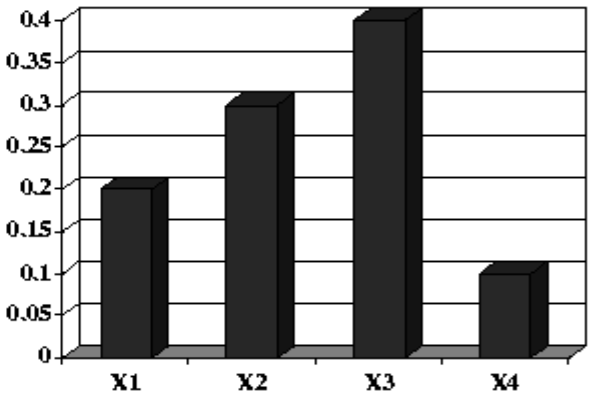
- Finite set of possible outcomes

$$X \in \{x_1, x_2, x_3, \ldots, x_n\}$$

$$P(x_i) \geq 0$$

$$\sum_{i=1}^{n} P(x_i) = 1$$

X binary: $P(x) + P(\overline{x}) = 1$



連續型機率分配

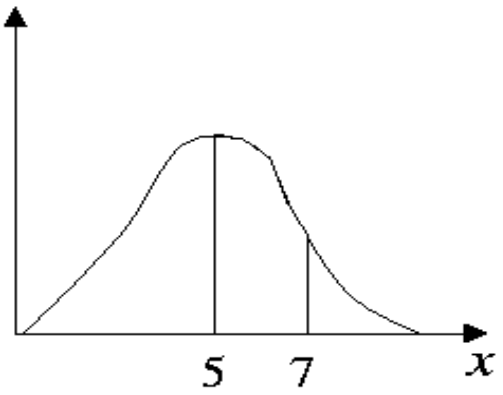
Continuous Random Variable

- Probability distribution (density function) over continuous values

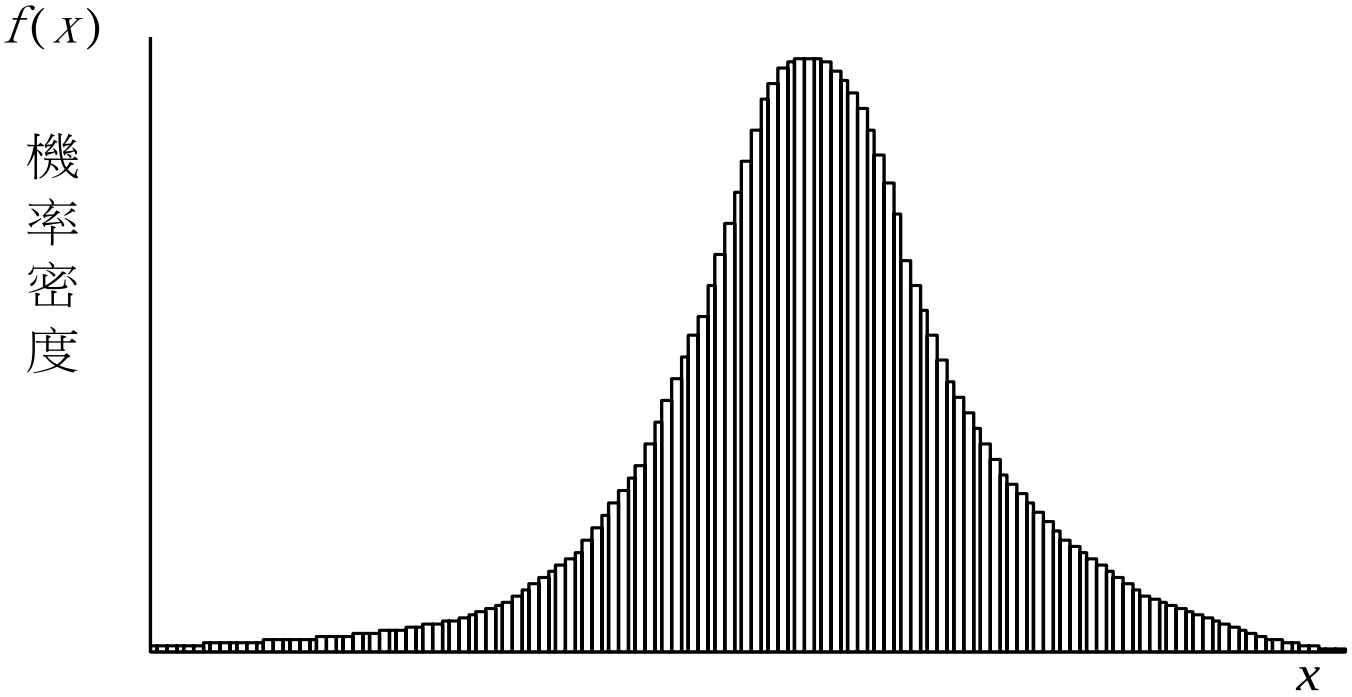
$$X \in [0,10] \qquad P(x) \geq 0$$

$$\int_0^{10} P(x)\,dx = 1$$

$$P(5 \leq x \leq 7) = \int_5^7 P(x)\,dx$$

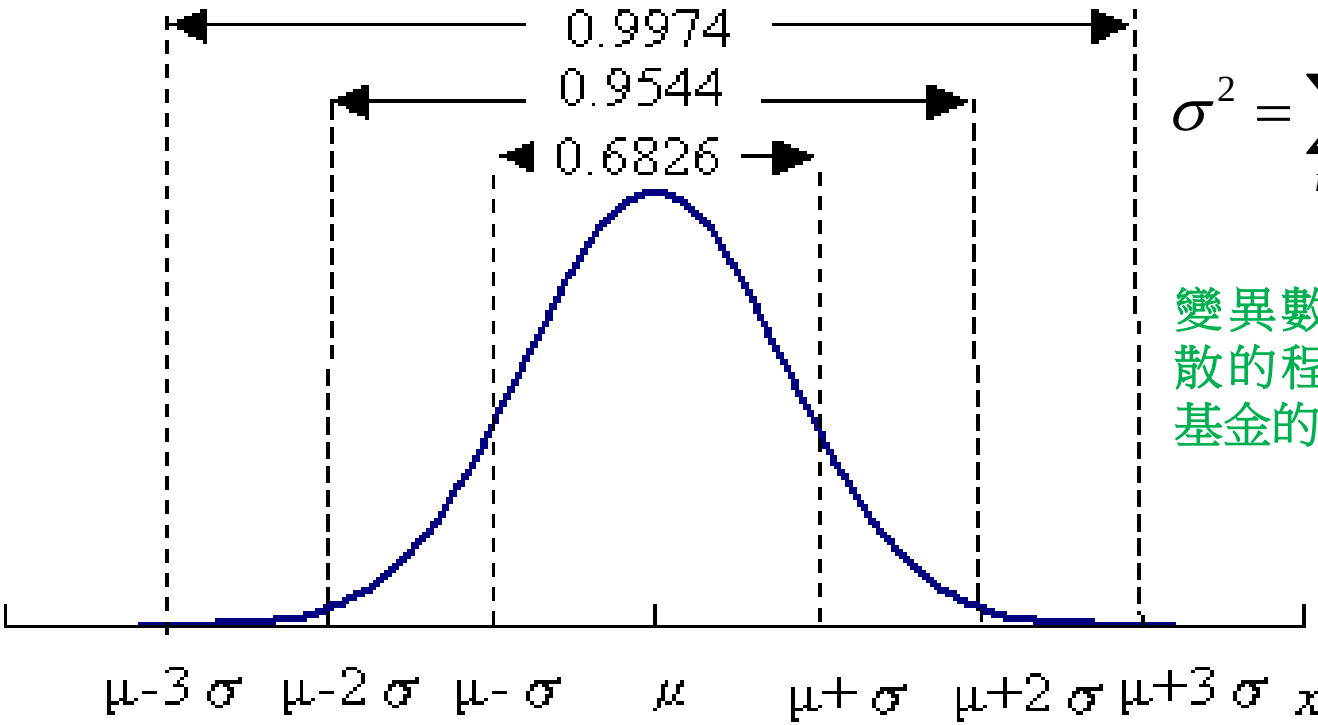


機率密度函數 (PDF)



機率密度函數(probability density function) ，為一數學函數，通常可想成當連續型變數(溫度、壓力)之直方圖機率分配 (組距趨近無窮小時)。

什麼是常態分配(又稱高斯/鐘型分配)?



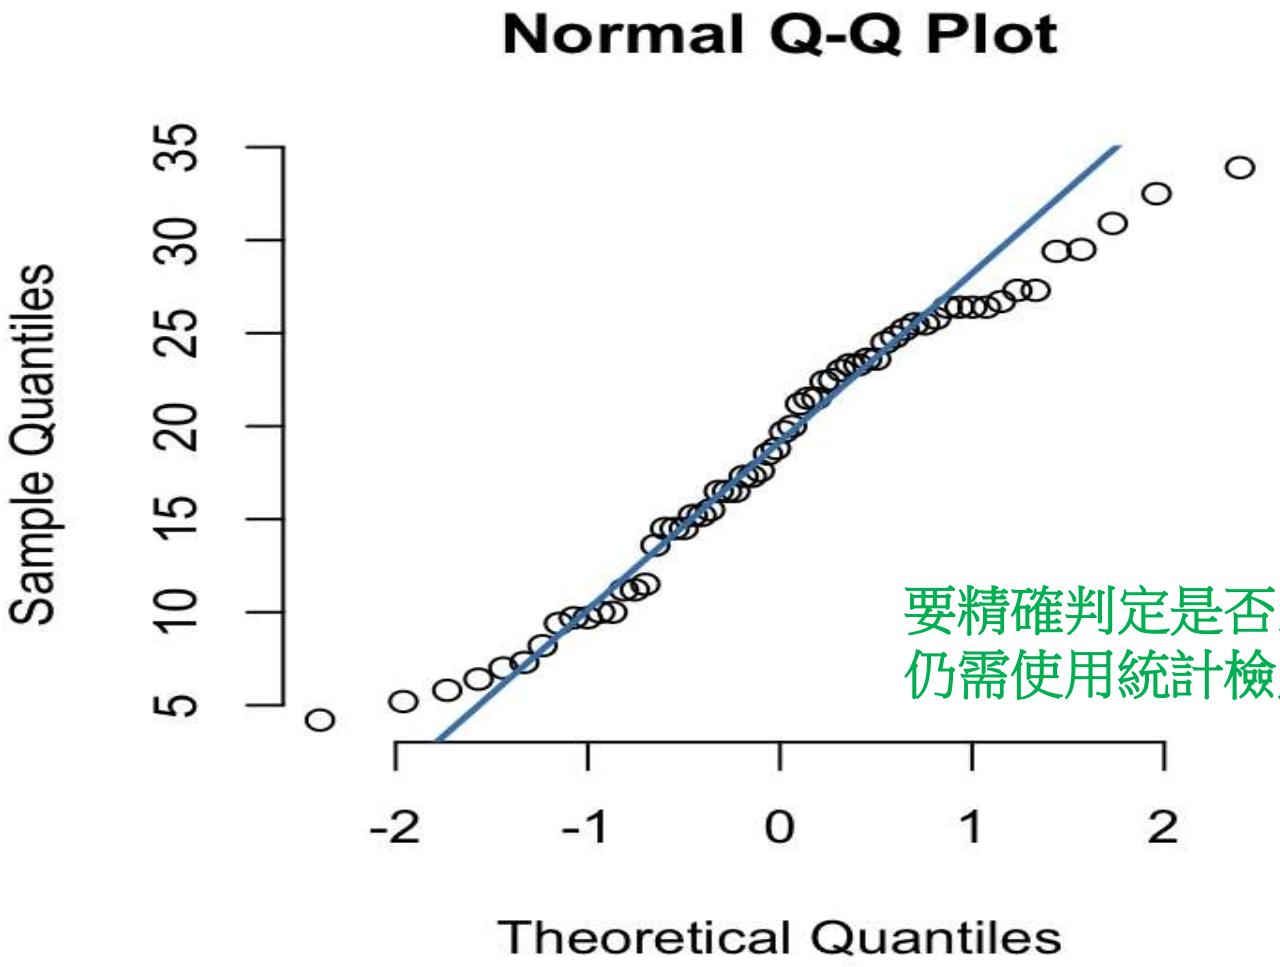
$$\sigma^2 = \sum_{i=1}^{N} \frac{(x_i - \mu)^2}{N}$$

變異數表示變數分散的程度想像共同基金的投資？?

標準常態分配(standard normal distribution)，為一平均值為0、標準差為1的常態分配 ($Z=X-\mu/\sigma$)。

曲線下的面積表示積分後得到的機率

Q-Q plot 以視覺化判定是否為常態分配



要精確判定是否為常態分配
仍需使用統計檢定

樣本對母體進行的不偏估計

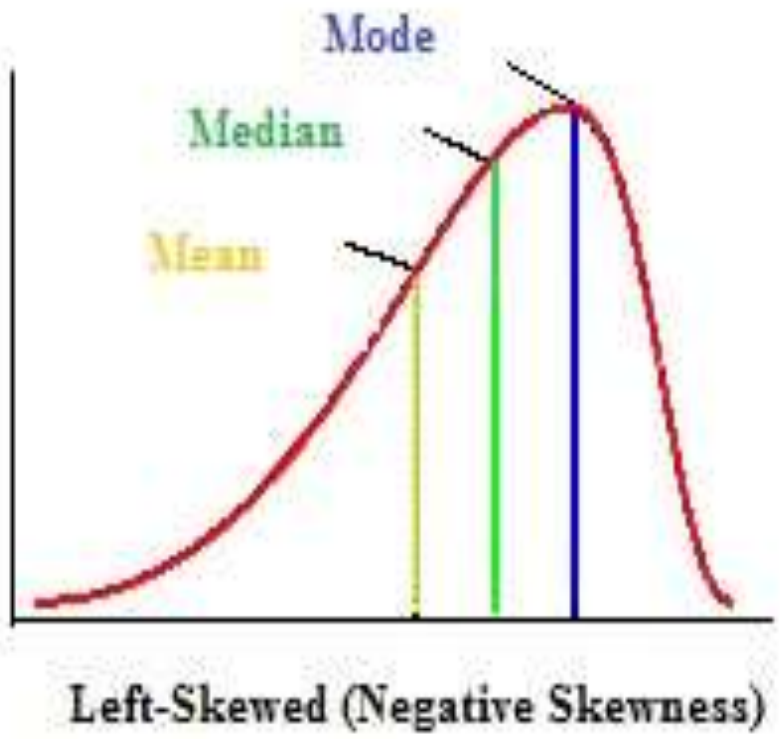
- 樣本平均值：$\bar{X}=\frac{\sum_{i=1}^{n} x_i}{n}$
- 樣本變異數：$S^2=\frac{\sum_{i=1}^{n} (x_i-\bar{X})^2}{n-1}$

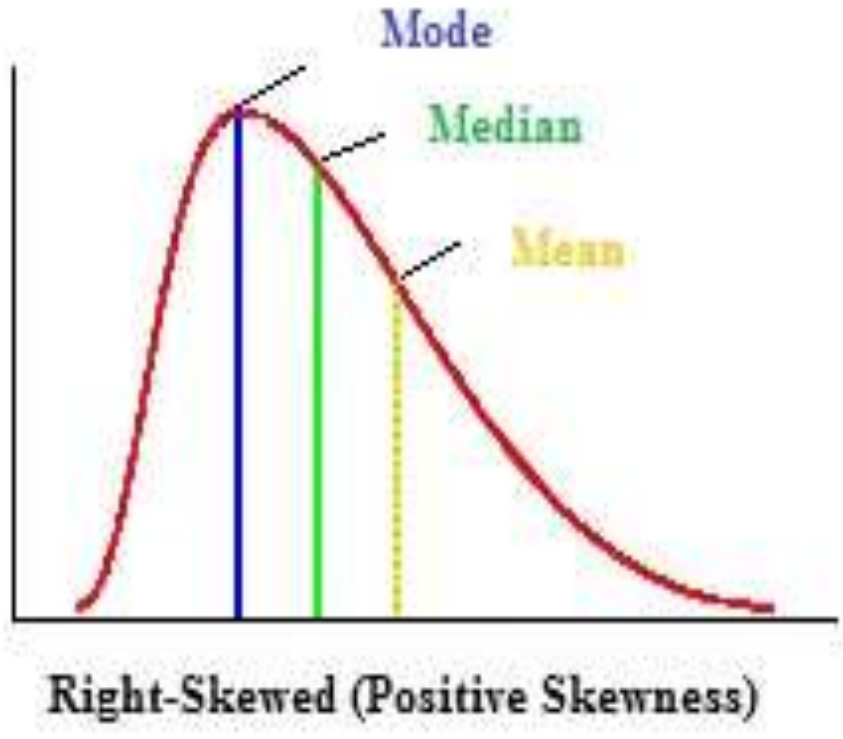
- 樣本平均是母體平均的不偏估計量　$E[\bar{X}] = \mu$
- 樣本變異是母體變異的不偏估計量　$E[S^2] = \sigma^2$

統計學告訴我們：

分母要除以(n-1)才會使該估計量為不偏估計量(不偏表示樣本估計量的期望值需等於母體待估計量)

什麼是skewness (偏度)?

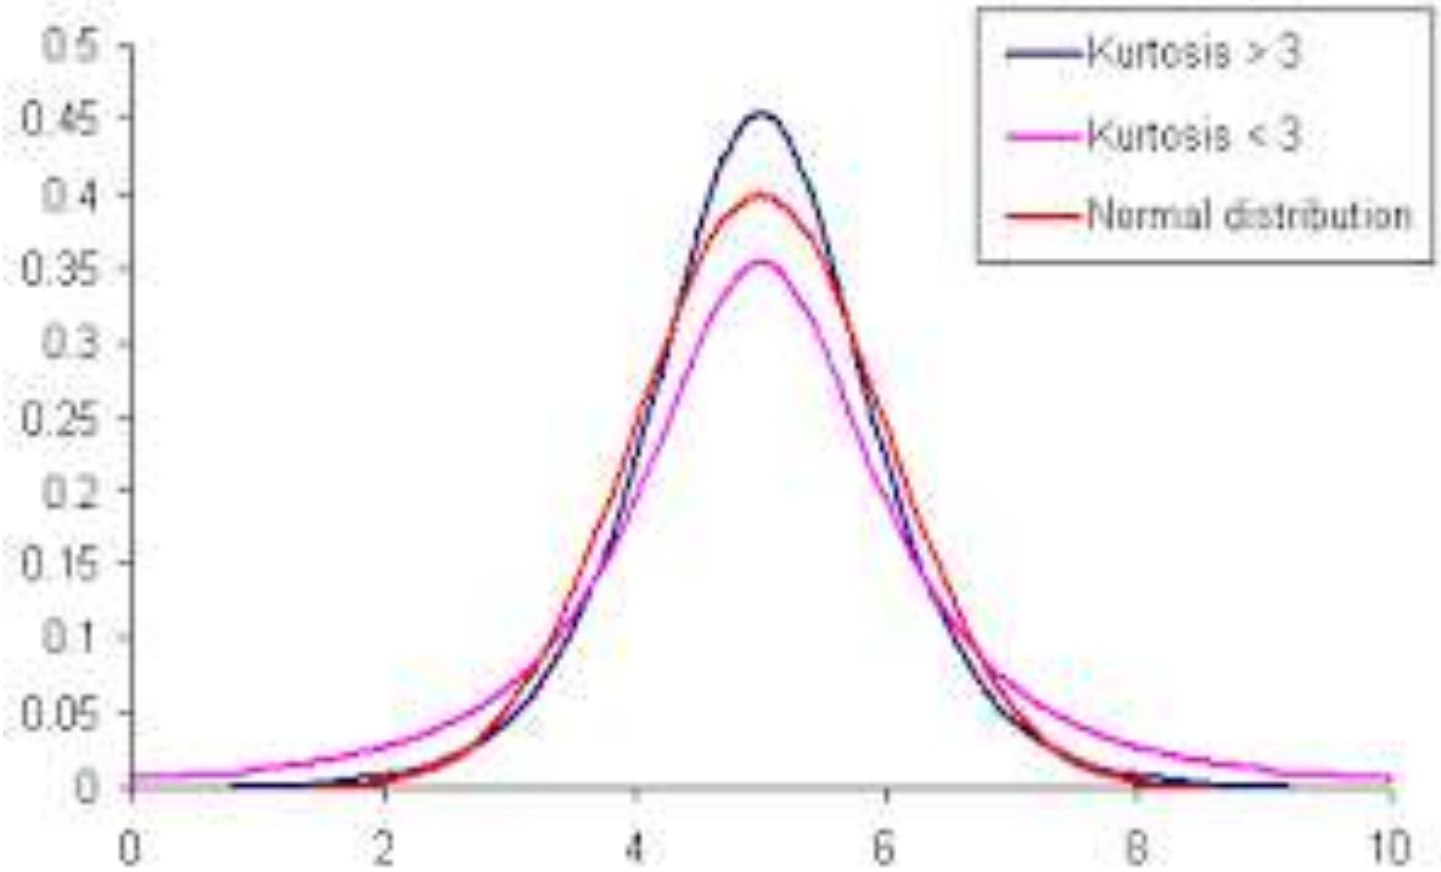




負(左)偏態表示高分群的樣本多　　正(右)偏態表示低分群的樣本多

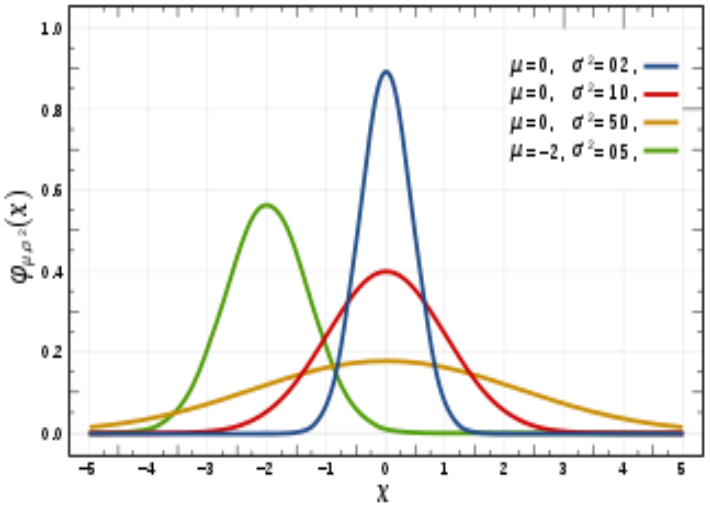
中位數左右的百分比均為50%

什麼是kurtosis (峰態)?



衡量分佈相對高斯分配較陡峭或較平坦

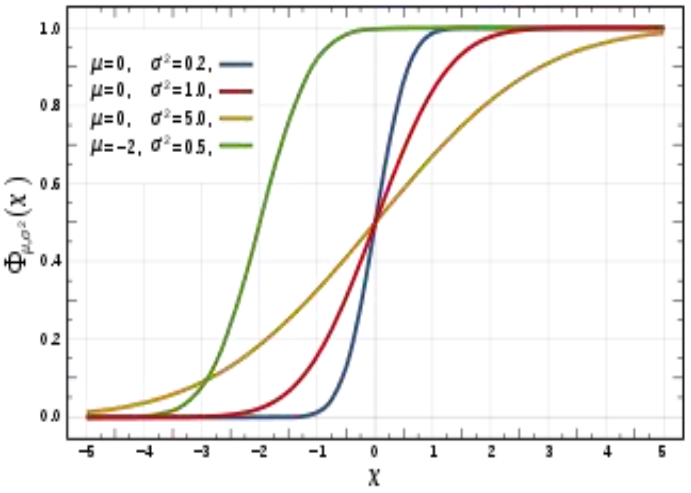
常見的機率分配



積分

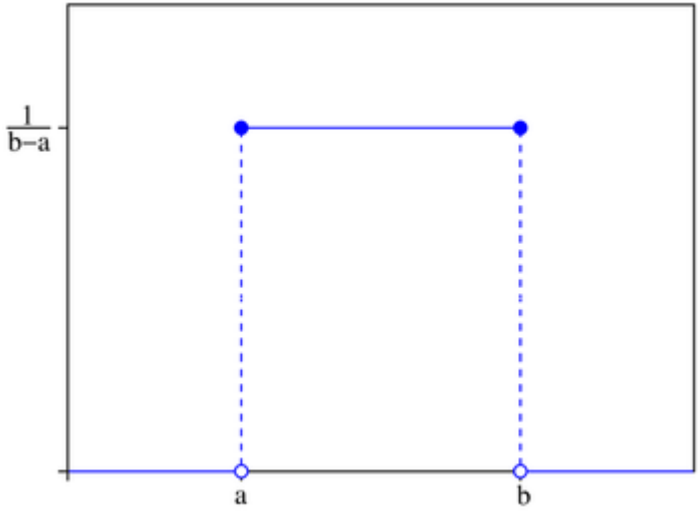
常態分配

微分



PDF: 機率密度

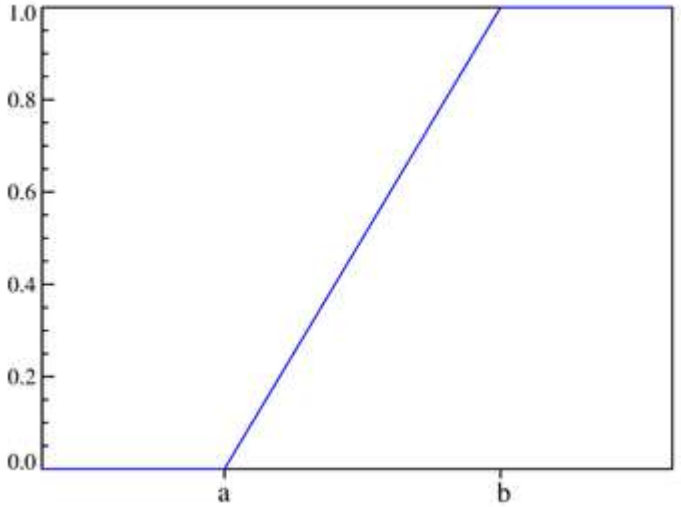
CDF: 累積機率密度



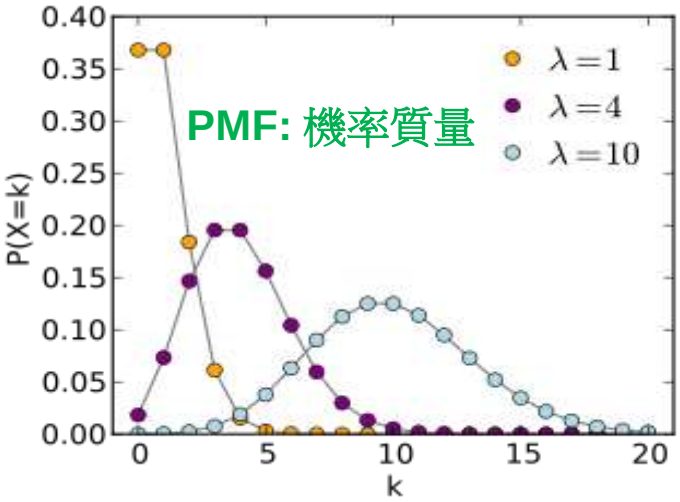
積分

均勻分配

微分



其他常見的機率分配一

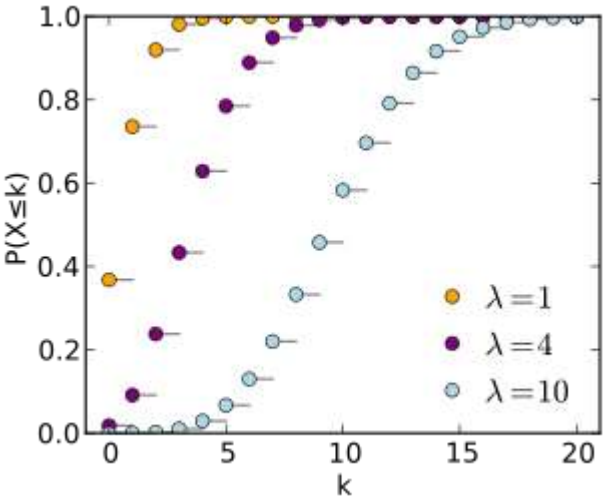


PMF: 機率質量

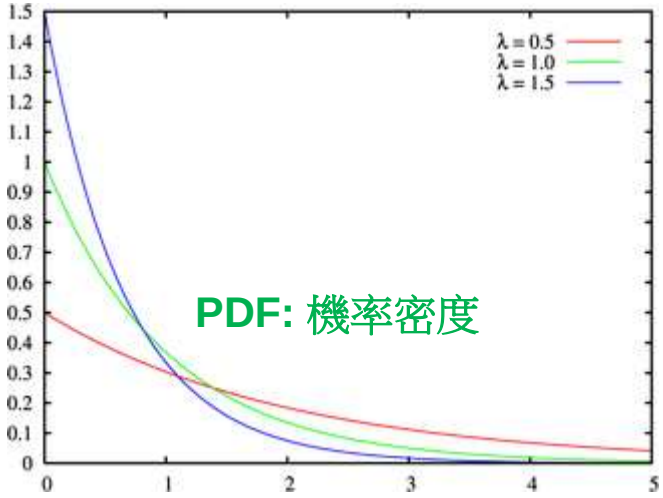
累加

Poisson分配

組間



CDF: 累積機率密度

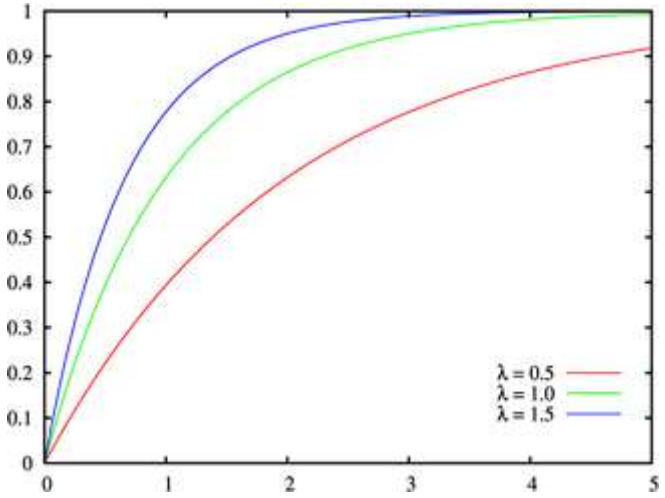


PDF: 機率密度

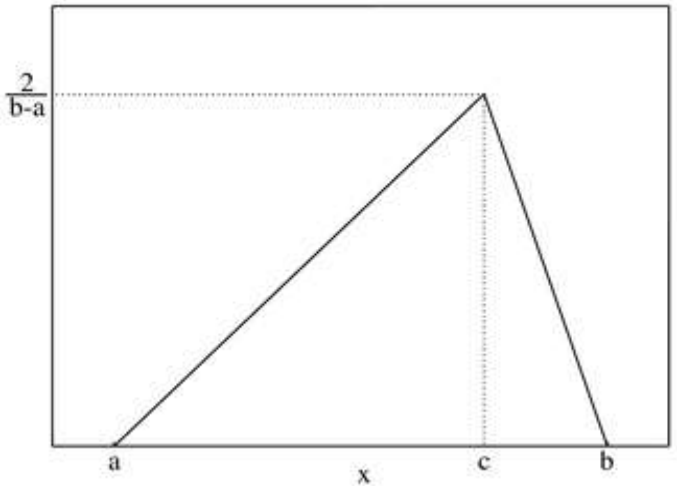
積分

指數分配

微分



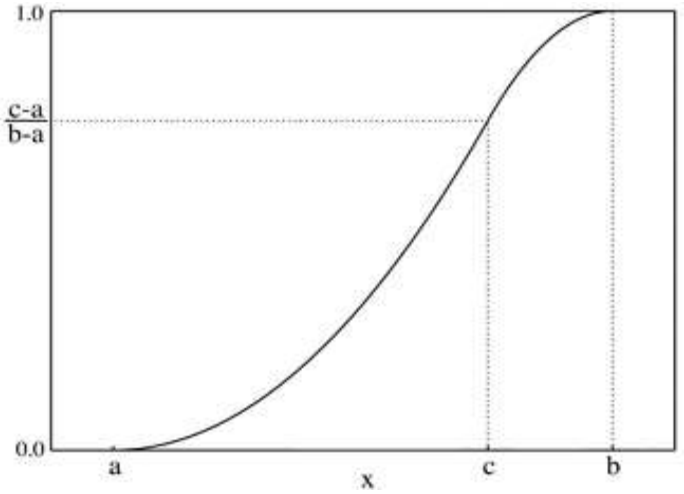
其他常見的機率分配二



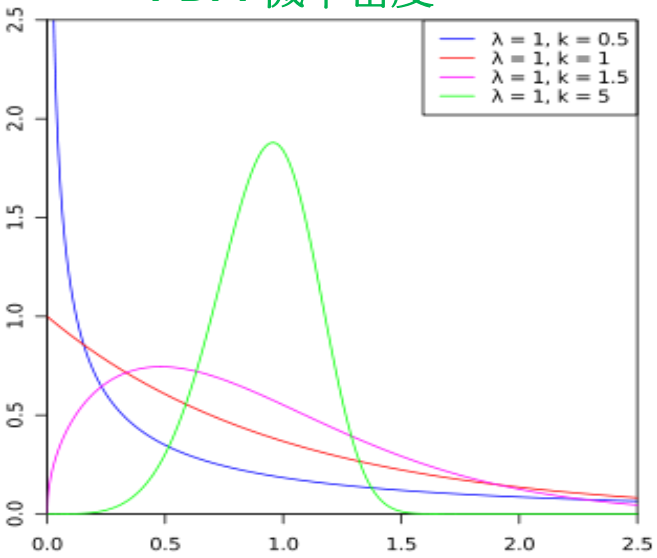
累加

三角分配

組間



PDF: 機率密度

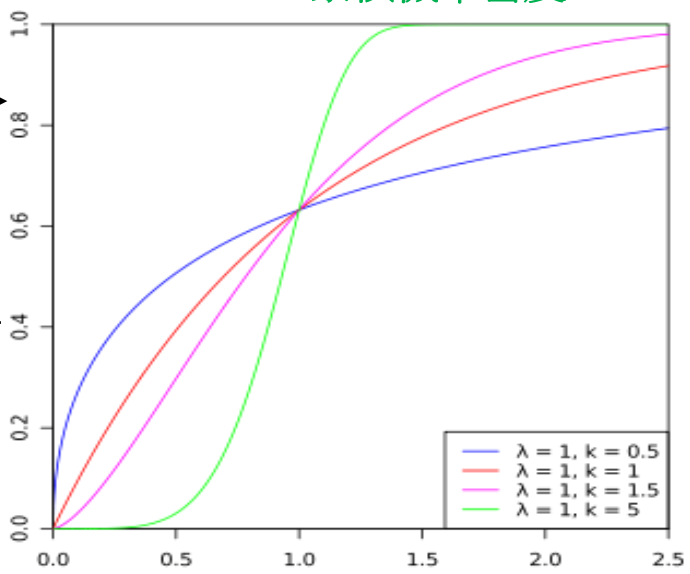


積分

Weibull分配

微分

CDF: 累積機率密度



卡方獨立性檢定

- 卡方獨立性檢定 (Chi-square Test of Independence)：
  分析兩個不同類別變數的分類次數分配，以決定該兩變數間是否獨立。

  例如：化學公司想知道不同膠料與晶圓種類是否對機台效能有關、理財公司也希望分析投資標的與風險偏好是否有關、行銷分析師可能希望研究消費者購買車型或顏色是否受到性別的影響。這些種種探討兩個類別變數間是否獨立的問題，均可利用卡方統計來進行分析。

- 思考一下，前面例子列聯表當中探討的數據為何？

卡方獨立性檢定（r × c列聯表）

- 卡方獨立性檢定可以用來分析各種型態的資料，尤其是最常用於名目尺度的資料。在資料分析中的兩個變數代表兩種不同的類別，資料(離散化後)觀察到的結果，通常可交叉整理成列聯表 。
- 列聯表(contingency table)：將資料用兩種不同分類方法，分類結果用行與列共同表示。

	B				
A	B_1	B_2	…	B_c	總計
A_1	O_{11}	O_{12}	…	O_{1c}	$O_{1.}$
A_2	O_{21}	O_{22}	…	O_{2c}	$O_{2.}$
⋮	⋮	⋮	⋮	⋮	⋮
A_r	O_{r1}	O_{r2}	…	O_{rc}	$O_{r.}$
總計	$O_{.1}$	$O_{.2}$	…	$O_{.c}$	$O_{..}=n$

卡方獨立性檢定(續)

- 若虛無假設正確，則樣本資料在列聯表中之期望次數為行總和與列總和的乘積再除以樣本大小。

$$E_{ij} = n \cdot \frac{O_{i\cdot}}{n} \cdot \frac{O_{\cdot j}}{n} = \frac{O_{i\cdot} \cdot O_{\cdot j}}{n} \quad ; \quad i=1,2,\ldots,r \quad j=1,2,\ldots,c$$

- 卡方獨立性檢定通常只適用於大樣本，一般說來，當所有的$E_{ij} \geq 5$時，卡方適合度檢定才適用。若有$E_{ij} < 5$時，很容易產生異常大的卡方檢定統計量，因此該行或該列分類就必須與相鄰行或列合併至$E_{ij} \geq 5$為止。

卡方獨立性檢定之假設

- 卡方獨立性檢定過程

卡方值代表實際值與期望值的差異平方和，越大表示兩變數越有關

H_0：列分類與行分類獨立(虛無：機台與材料無關)

H_a：列分類與行分類相關(對立：機台與材料有關)

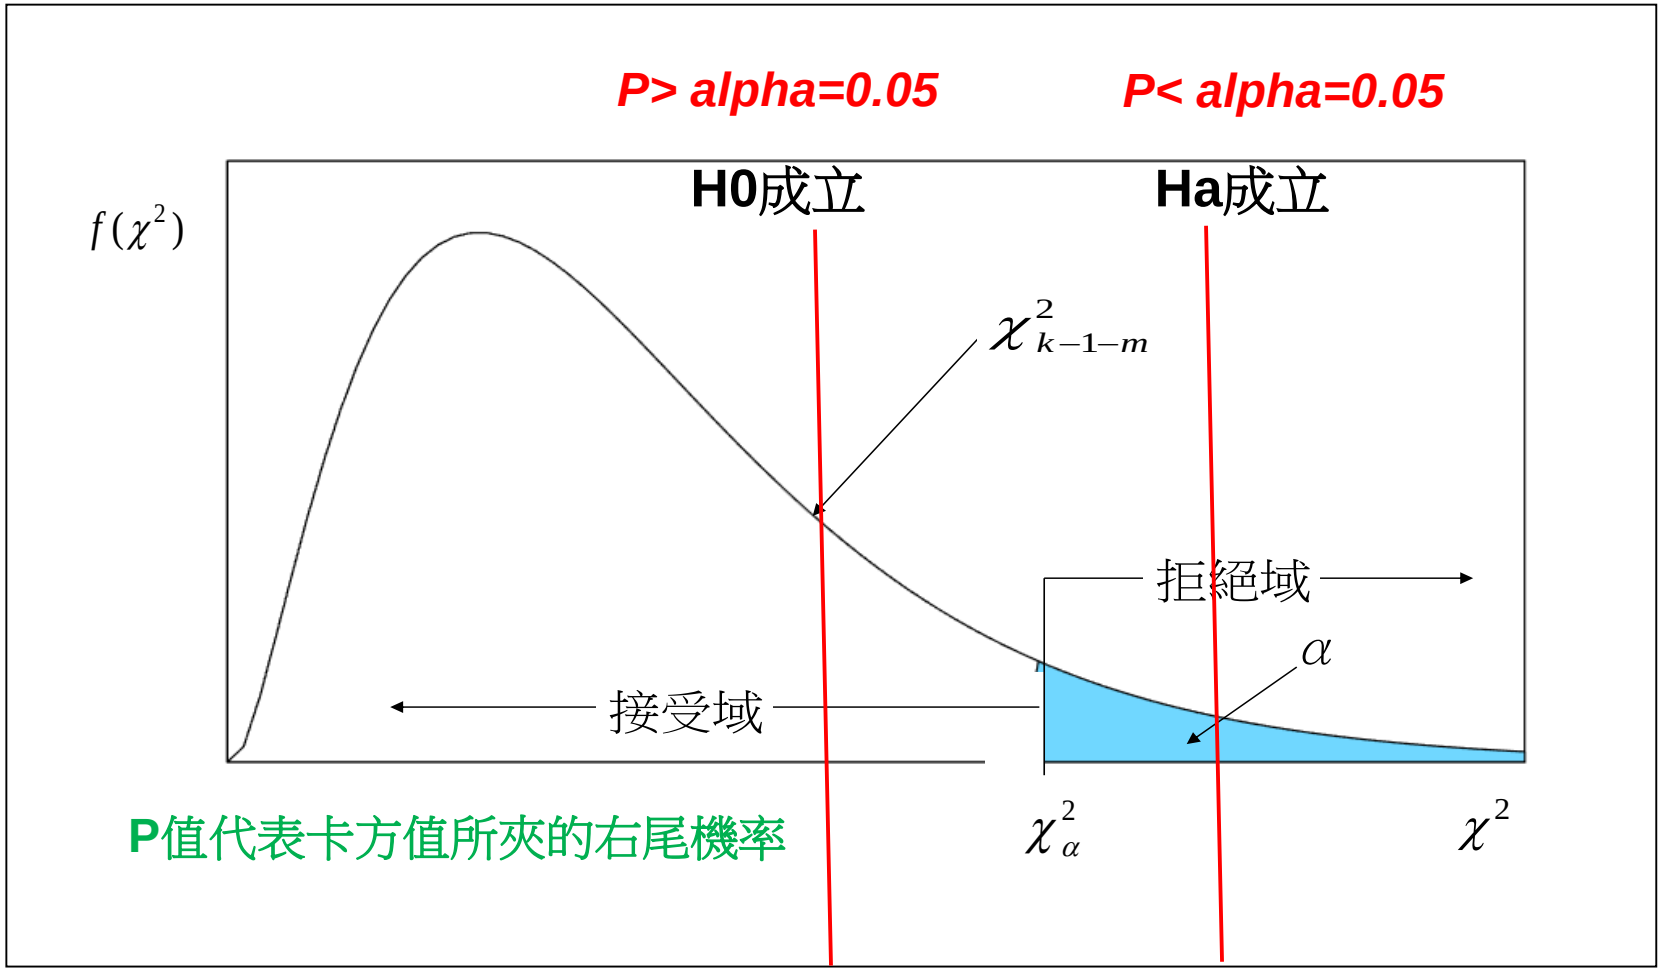
✓檢定統計量：χ^2, 自由度為(r－1)(c－1)之卡方統計量。

✓拒絕域：$\chi^2 > \chi^2_{(r-1)(c-1),\alpha}$

✓ p值：$If(\chi^2_{(r-1)(c-1)} > \chi_\alpha^{*2})$ then $p < \alpha$

拒絕域表示行列變數有關，此時右尾面積會小於自訂臨界值alpha=0.05

卡方檢定的拒絕域與接受域



P值代表卡方值所夾的右尾機率

兩母體比例差的檢定

- 檢定P_1-P_2的點估計與區間估計。

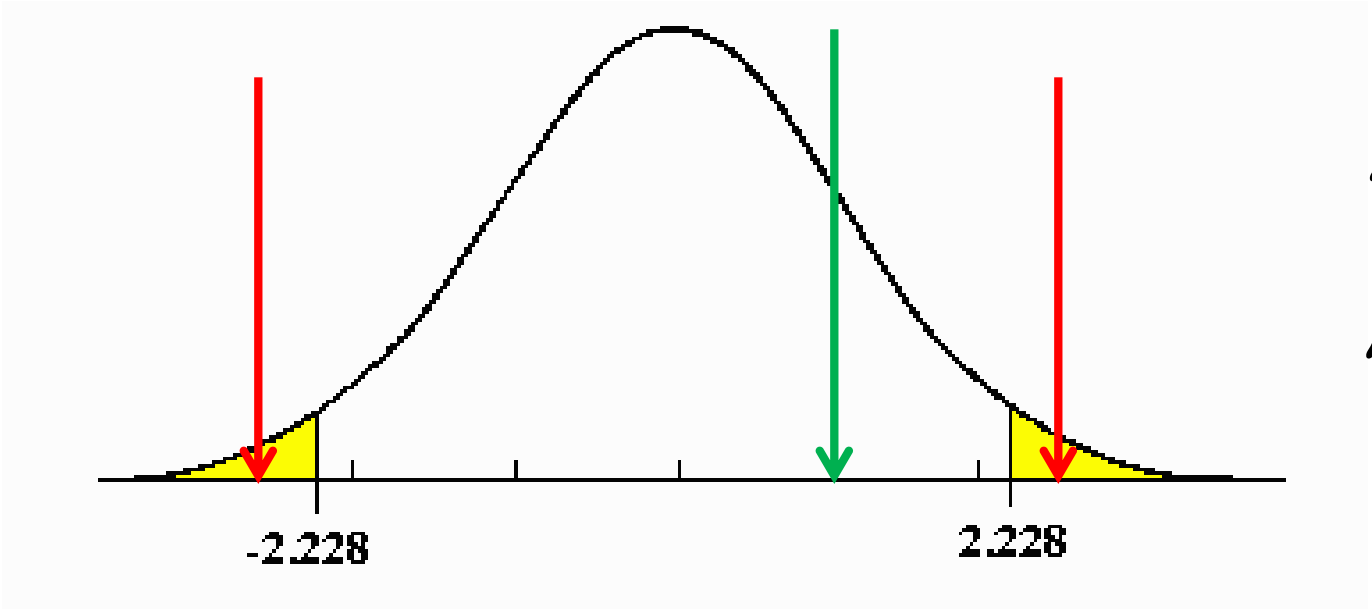
$$E\left(\overline{P}_1-\overline{P}_2\right)=P_1-P_2\approx 0\,??$$

$$\sigma_{\left(\overline{P}_1-\overline{P}_2\right)}=\sqrt{\frac{P_1\left(1-P_1\right)}{n_1}+\frac{P_2\left(1-P_2\right)}{n_2}}$$

虛無：兩者比例無差異
對立：兩者比例有差異

- Example：
  - 調查荷商ASML及美商應用材料的機台對某製程的良率指標，從ASML中抽出5000個，其中2400個瑕疵；從應材抽出2000個，其中1200個瑕疵，求出ASML與應材機台對此製程的瑕疵比例差距的95%信賴區間 (-0.1414 , -0.0986)？
  - 信賴區間不包含0 (P<0.05)，所以兩品牌的瑕疵比例具有顯著差異；且因信賴區間分布在負值，斷定ASML的瑕疵比例較應材為低

雙尾假設檢定 VS. 法律定罪



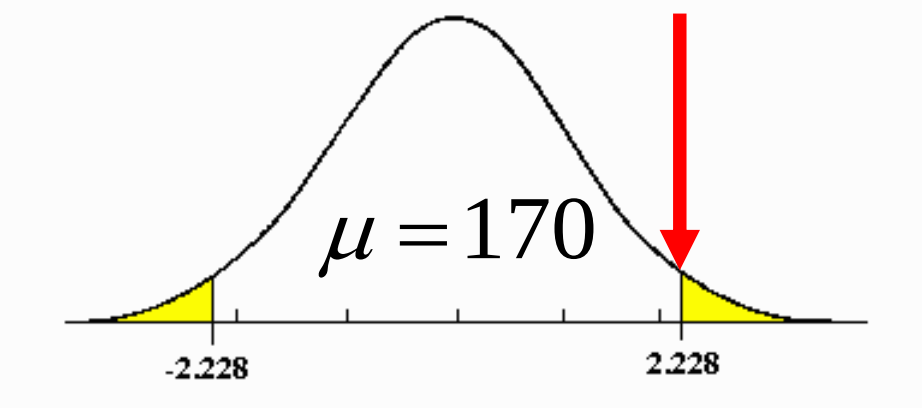
$$\mu = 170$$

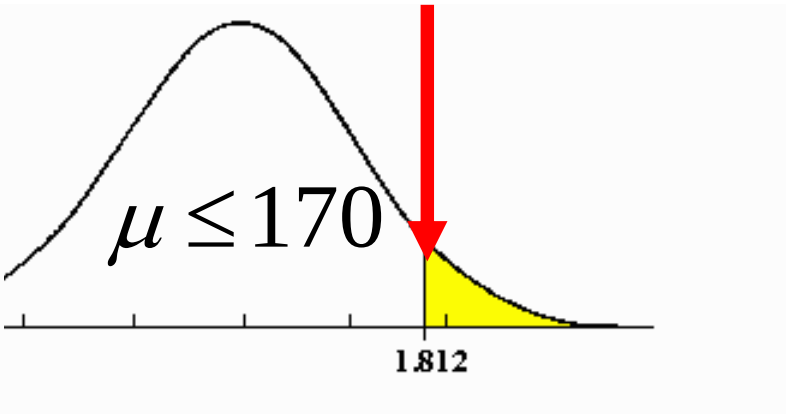
$$\mu \neq 170$$

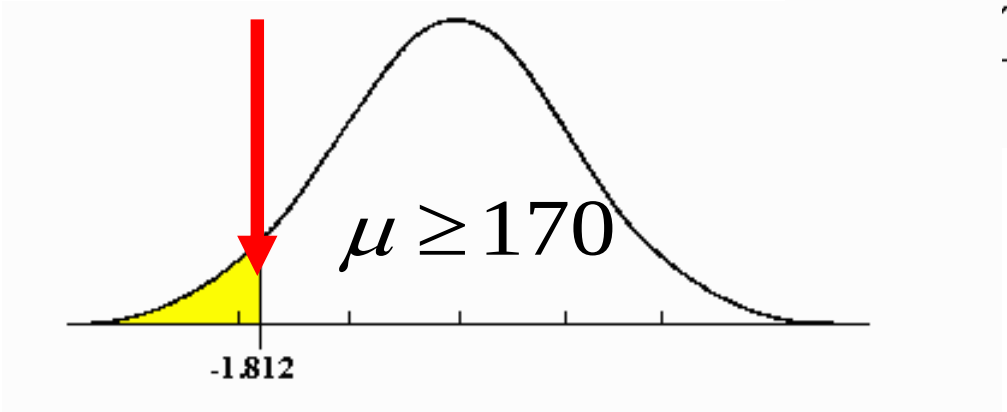
白色區域維接受域，表示虛無假設成立 **(P>0.05)**
黃色區域維拒絕域，表示對立假設成立 **(P<0.05)**

虛無假設(法官立場原則上採無罪推定)？
對立假設(檢察官立場拼命找證據起訴)？

單尾與雙尾之T-tests (df=10)







單一樣本 *t* 檢定(one sample *t* test)

- 比較母體平均值與一特定值。決策法則為何時拒絕 H_0，採 *p*-value 法來判斷，其判斷準則依單、雙尾整理如下表。

	單尾（以右尾為例） $H_0 : \mu \le \mu_0$ $H_1 : \mu > \mu_0$	雙尾 $H_0 : \mu = \mu_0$ $H_1 : \mu \ne \mu_0$
p-value 法	$P(Z > \overline{X}\|\mu_0)$ $= P\left(Z > \dfrac{\overline{X} - \mu_0}{\dfrac{\sigma}{\sqrt{n}}}\right) < \alpha$	$Min\left\{\begin{array}{l} 2P(Z > \overline{X}\|\mu_0) = 2P\left(Z > \dfrac{\overline{X} - \mu_0}{\dfrac{\sigma}{\sqrt{n}}}\right) \\ 2P(Z < \overline{X}\|\mu_0) = 2P\left(Z < \dfrac{\overline{X} - \mu_0}{\dfrac{\sigma}{\sqrt{n}}}\right) \end{array}\right. < \alpha$

二個獨立樣本平均數差的統計推論

- X1與X2是來自兩個母體的獨立樣本，其統計量：

$$\bar{X}_1, \bar{X}_2, s_1^2, s_2^2$$

- $\bar{X}_1 - \bar{X}_2$的抽樣分配

$$E\left(\bar{X}_1 - \bar{X}_2\right) = \mu_1 - \mu_2 = \mu_{(\bar{X}_1 - \bar{X}_2)}$$

$$Var\left[\bar{X}_1 - \bar{X}_2\right] = \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} = \sigma_{(\bar{X}_1 - \bar{X}_2)}$$

大樣本μ_1-μ_2之抽樣分配

- 檢定：
$$z=\frac{(\bar{X}_1-\bar{X}_2)-(\mu_1-\mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}} \qquad t=\frac{(\bar{X}_1-\bar{X}_2)-(\mu_1-\mu_2)}{\sqrt{\frac{S_1^2}{n_1}+\frac{S_2^2}{n_2}}}$$

- 信賴區間：
$$(\bar{X}_1-\bar{X}_2)\pm Z_{\left(\frac{\alpha}{2}\right)}\cdot\sigma_{(\bar{X}_1-\bar{X}_2)}$$

- Z檢定: 母體的標準差已知時,進行Z檢定。母體的標準差未知時,進行T檢定。
- 平均值的抽樣檢定,因母體的標準差大多無法得知,很少使用Z檢定, T檢定隨自由度改變,當*n*大於30時z分配與*t*分配十分接近,因此在資料分析實務上,多以T檢定來進行樣本平均數的差異檢定。

兩組樣本的平均值是否相等

獨立樣本 *t* 檢定(independent samples *t* test)：比較來自兩母體之獨立樣本，檢定平均值之差異是否顯著。

- 比較產品破片數是否因機台而有所不同？
  - 虛無假設H_0：機台1與機台2的平均破片數無差異

    ($\mu_0-\mu_1=0$或$\mu_0=\mu_1$)
  - 對立假設H_1：機台1與機台2的平均破片數有差異

    ($\mu_0-\mu_1\neq0$或$\mu_0\neq\mu_1$)

- 配對樣本 *t* 檢定(paired-samples *t* test)：使用同一樣本作為實驗組與對照組，如比較機台調校前和調校後之生產效能是否有差異，此種樣本稱為配對樣本，又稱相依或成對樣本。

兩組樣本的變異數是否相等

- 若使用者希望看兩組兩組之間的平均值有沒有差別，而不是看一個整體的，此時就需要使用獨立樣本T檢定
- 獨立樣本T檢定之前，需先以F檢定確認各組變異數是否相同

  H_0-假設兩組變異數相等 $\sigma_1^2 = \sigma_2^2$　$\sigma_1^2/\sigma_2^2 = 1$?

  H_1-假設兩組變異數不等 $\sigma_1^2 \neq \sigma_2^2$

- *F*分配是什麼？ $F = \frac{x1^2/d1}{x2^2/d2}$,

  $x1^2$及$x2^2$表示卡方分配

  d1與d2表示自由度

平均值T檢定是用相減是否為0
變異數F檢定是用相除是否為1

ANOVA(變異數分析)的意義

- 「變異數分析」探討因子變異、交互作用對隨機變異的比值是否顯著，以判斷因子重要性
- 藉由分析不同組資料的變異數來檢驗不同條件是否會造成不同結果。
- 變異數分析其實就是F檢定的應用。
  (F test是1920年代由Ronald Fisher提出的統計方法。
  F test, *T* test和χ^2 test是三個最常見的統計檢定)

ANOVA三大假設

- 常態性假設：
  每組反應變數的母體均為常態分配

  $Y_i \sim N(\mu_i, \sigma^2),\ i=1,2,\ldots,k$

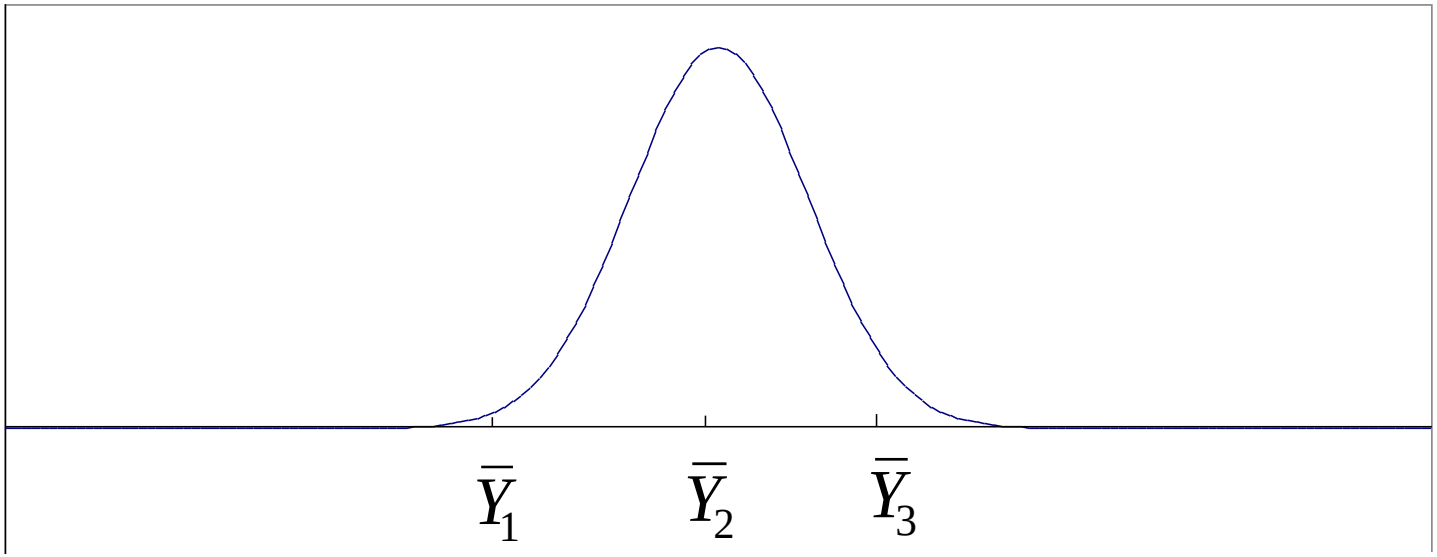
- 同質性假設：
  每組的母體變異數都相等

  $\sigma_i^2=\sigma^2$

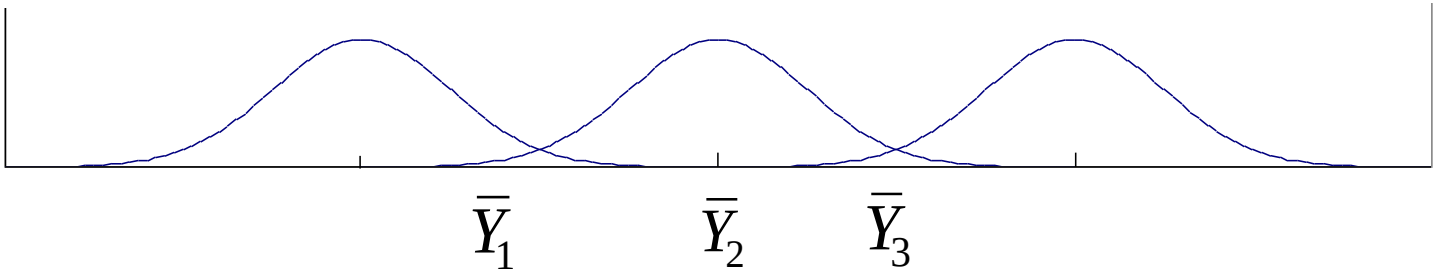
- 獨立性假設：
  抽自各母體的各組隨機樣本互為獨立。

ANOVA分析的虛無假設與對立假設

H_0為真時$\mu_1 = \mu_2 = \mu_3$ $E(MSF) = \sigma^2$ $\bar{Y}_1, \bar{Y}_2, \bar{Y}_3$的組間變異較小



H_0不真時 μ_i不會全等 $E(MSF) > \sigma^2$ $\bar{Y}_1, \bar{Y}_2, \bar{Y}_3$的組間變異較大



變異數分析(ANOVA)

- 總變異

  總變異 = 組間變異 + 隨機變異

  $$SST = SSF + SSE$$

- 因子變異(組間變異)

  $$SSF = \sum_{i=1}^{k}\sum_{j=1}^{n_i}(\bar{Y}_i - \bar{\bar{Y}})^2 \text{ 或 } \quad SSF = \sum_{i=1}^{k} n_i((\bar{Y}_i - \bar{\bar{Y}})^2$$

- 隨機變異(組內變異)

  $$SSE = \sum_{i=1}^{k}\sum_{j=1}^{n_i}(Y_{ij} - \bar{Y}_i)^2 \text{或} \quad SSE = \sum_{i=1}^{k}(n-1)S_i^2$$

檢定多個母體平均數是否相同

- 平均因子變異 $MSF = \frac{SSF}{k-1}$

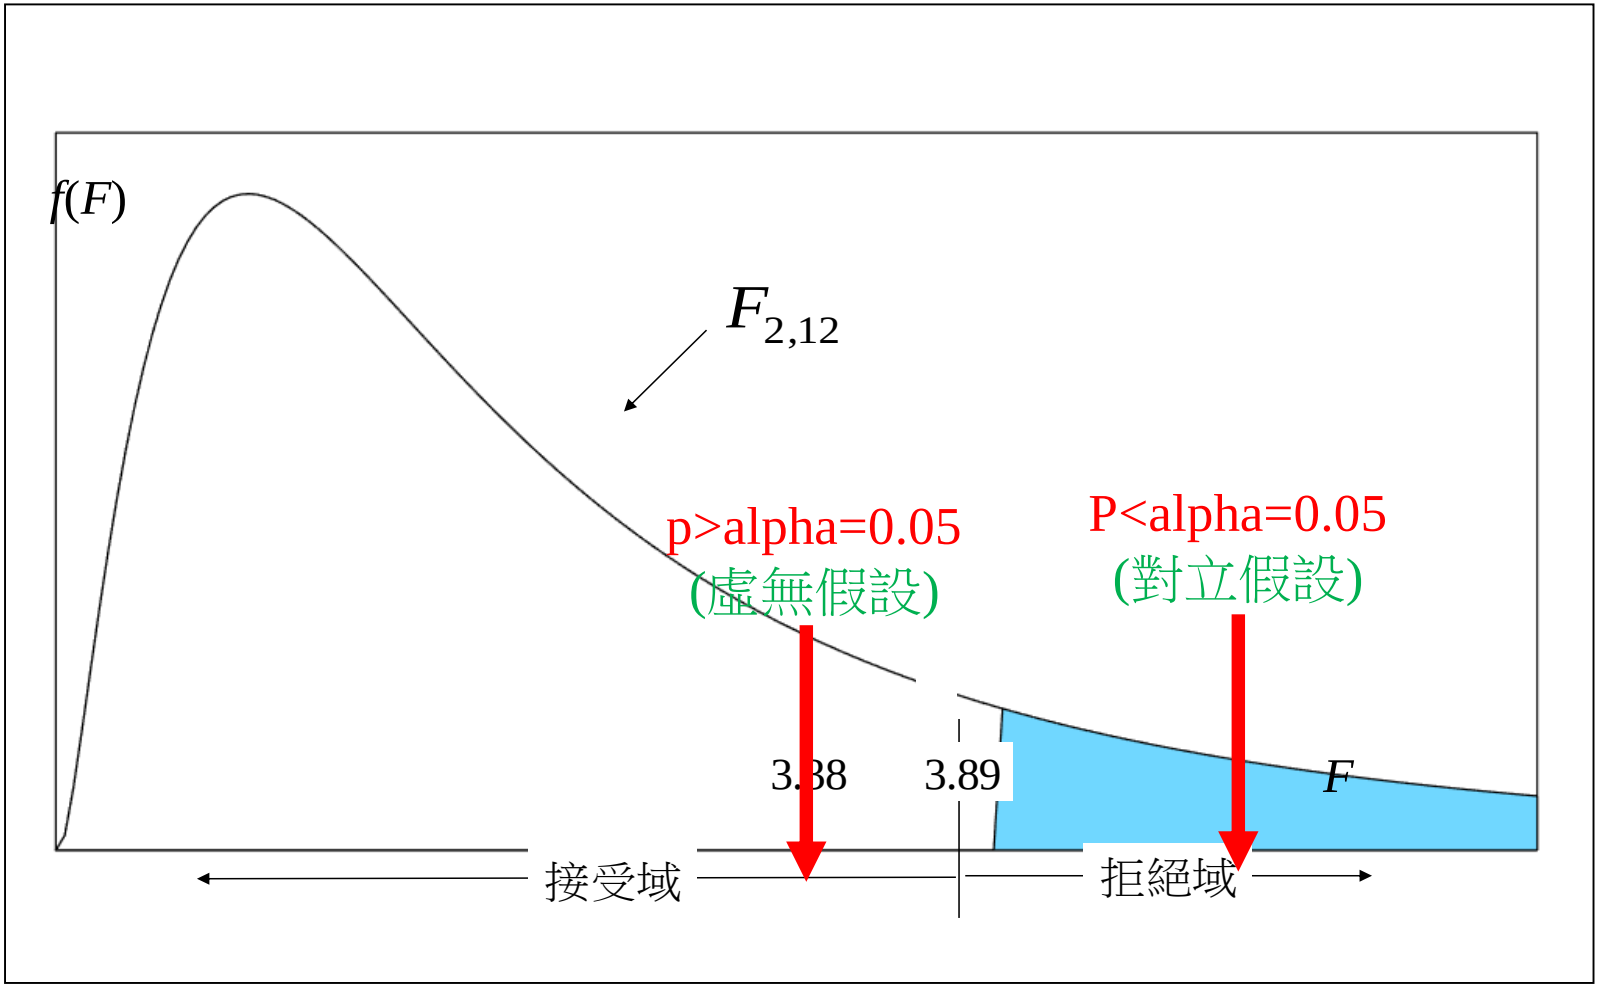
虛無：因子對Y無影響
對立：因子對Y有影響

- 平均隨機變異 $MSE = \frac{SSE}{\sum n_i - k}$

- F檢定統計量 $F = \frac{MSF}{MSE} \sim F_{k-1,\sum n_i - k}$

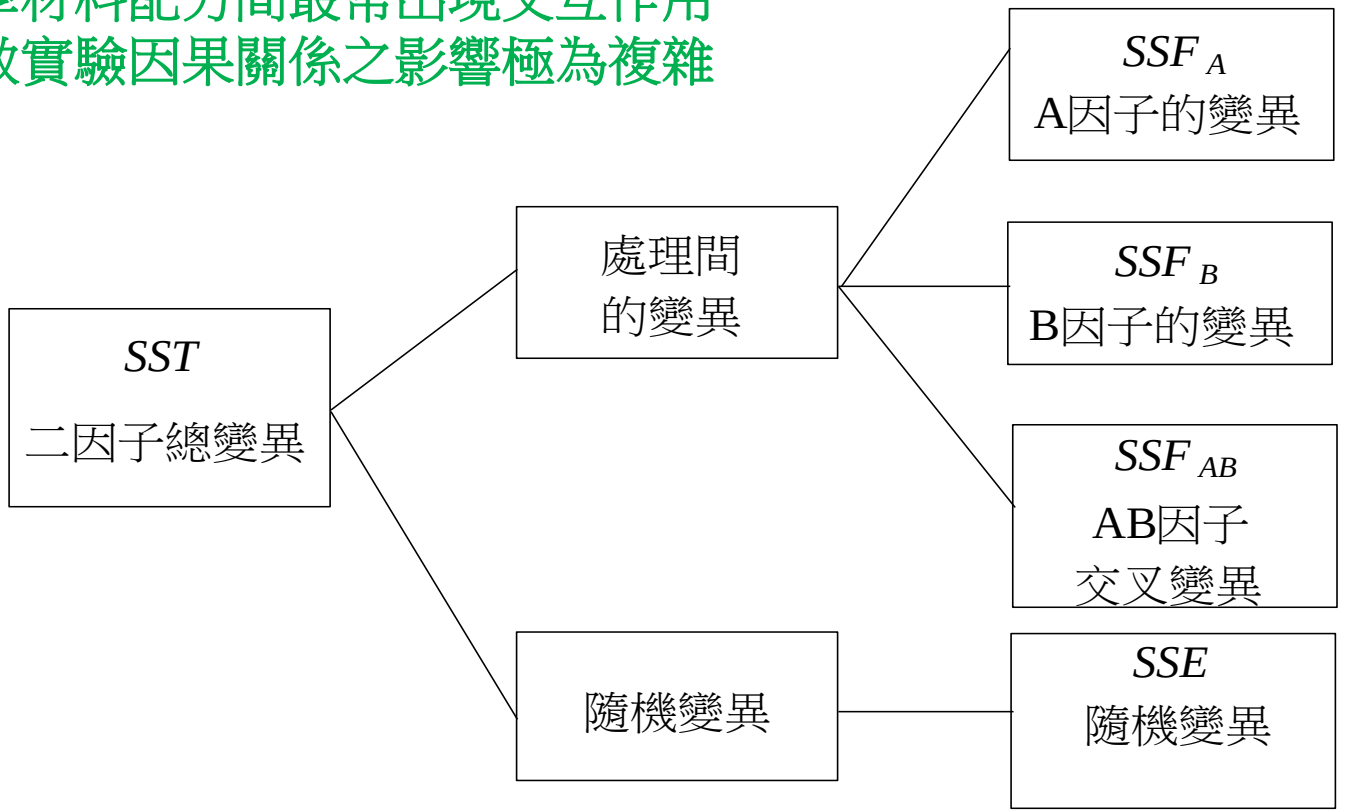
- 決策法則 (拒絕H_0才表示該因子足夠顯著)
- 若 $F > F_{k-1,\sum n_i - k,\alpha}$，則拒絕$H_0$ (p<alpha=0.05)
- 若 $F \le F_{k-1,\sum n_i - k,\alpha}$ ，則接受H_0 (p>alpha=0.05)

圖示F分配 (變異數)

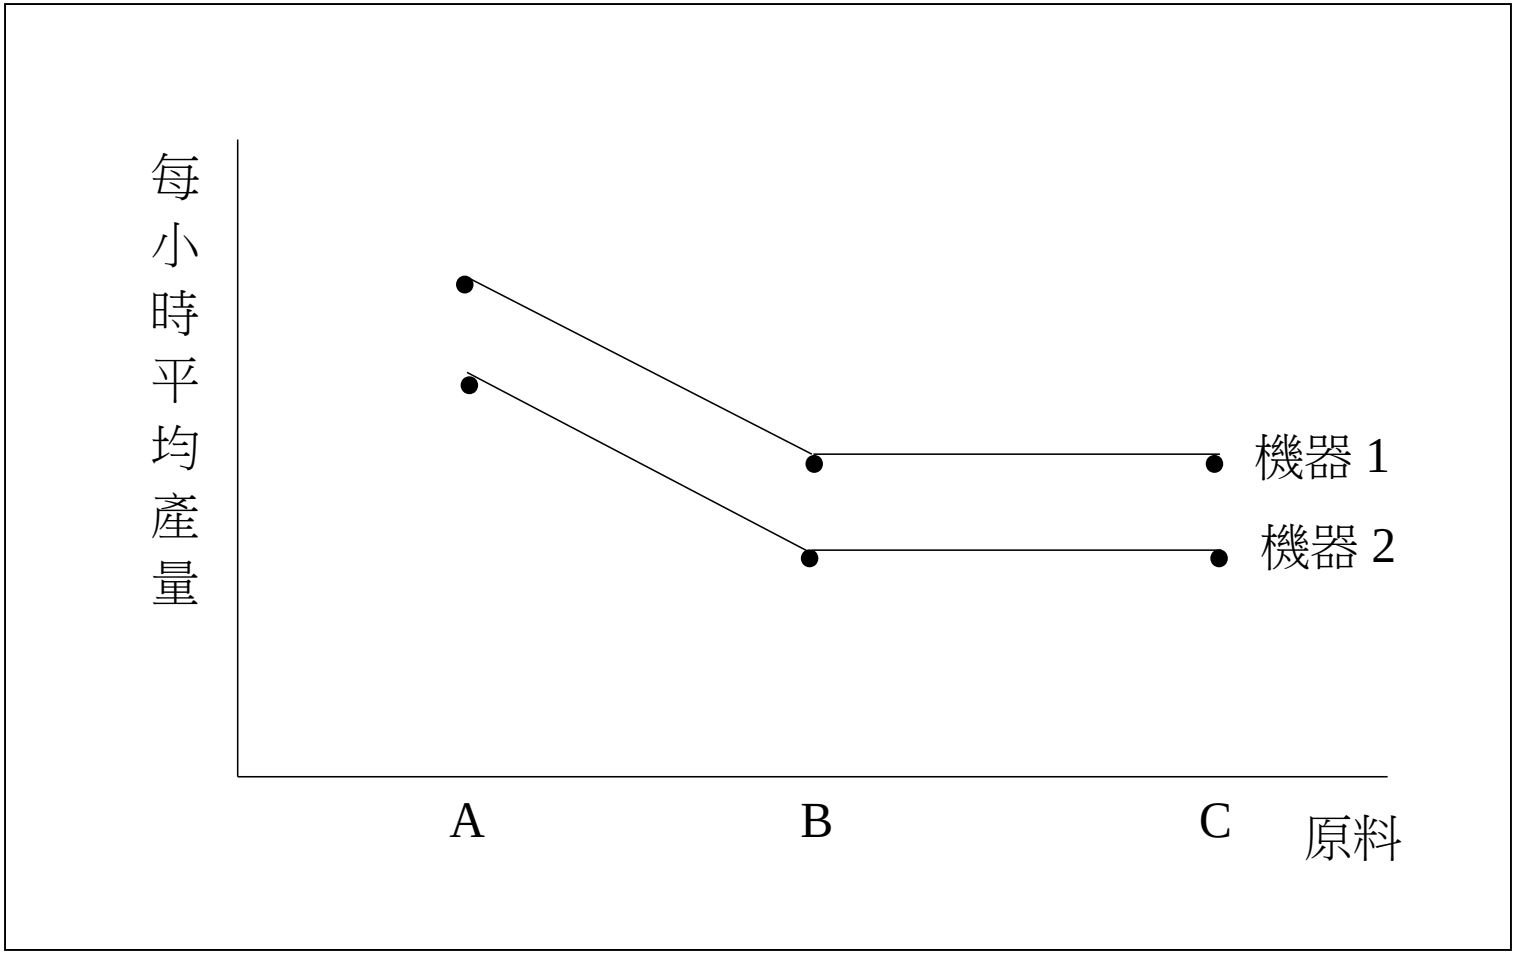


二因子變異數分析

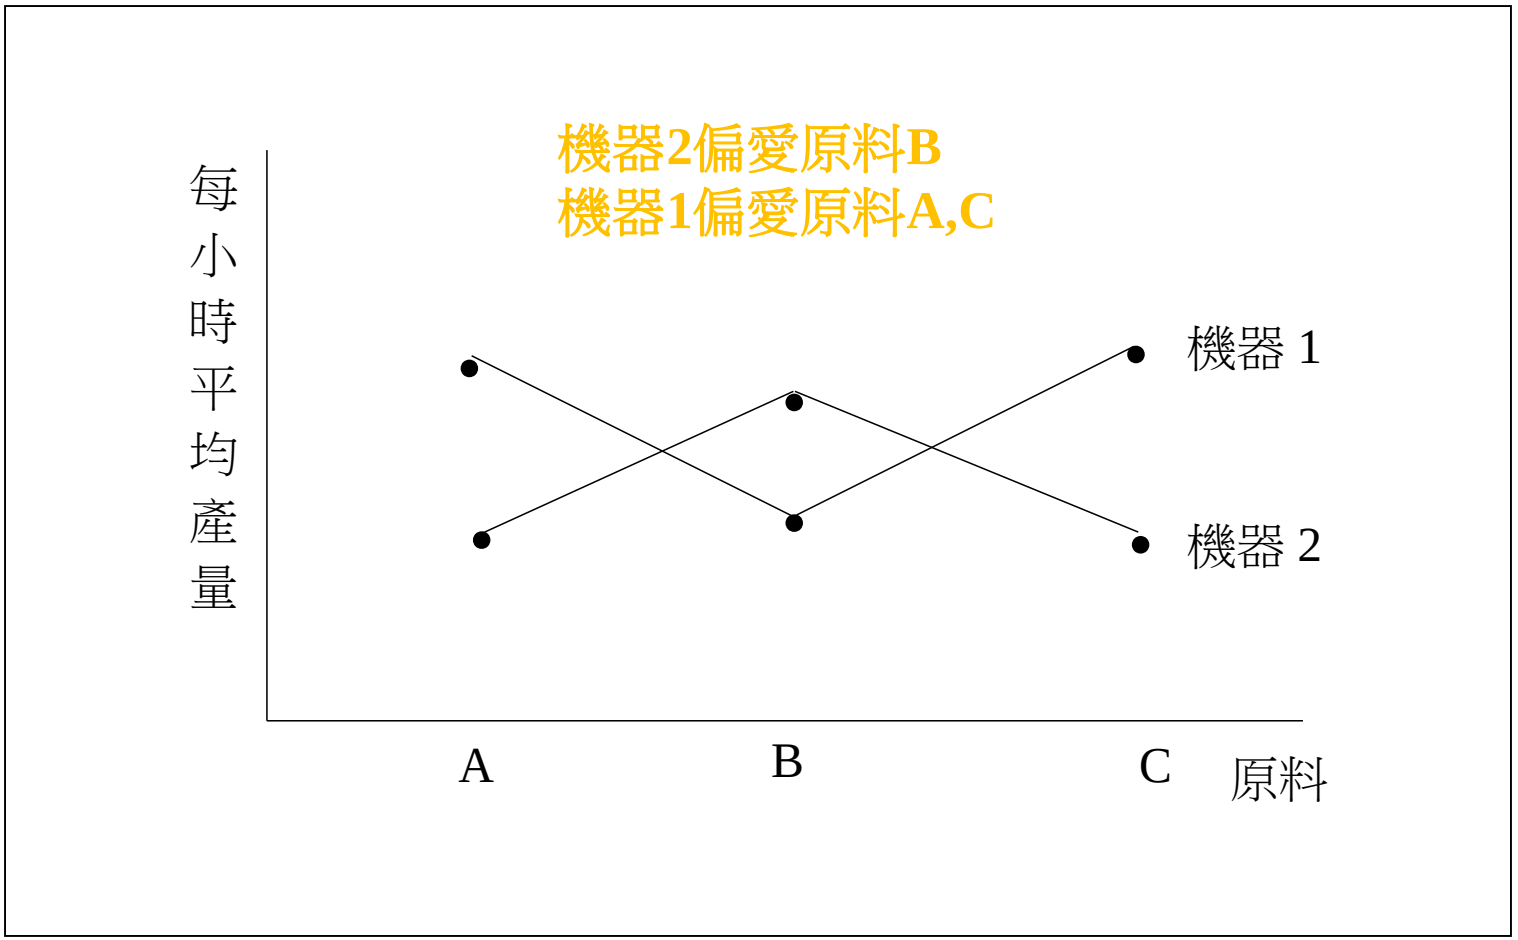
化學材料配方間最常出現交互作用
導致實驗因果關係之影響極為複雜



兩因子無交互作用



兩因子有交互作用



迴歸分析(Regression Analysis)

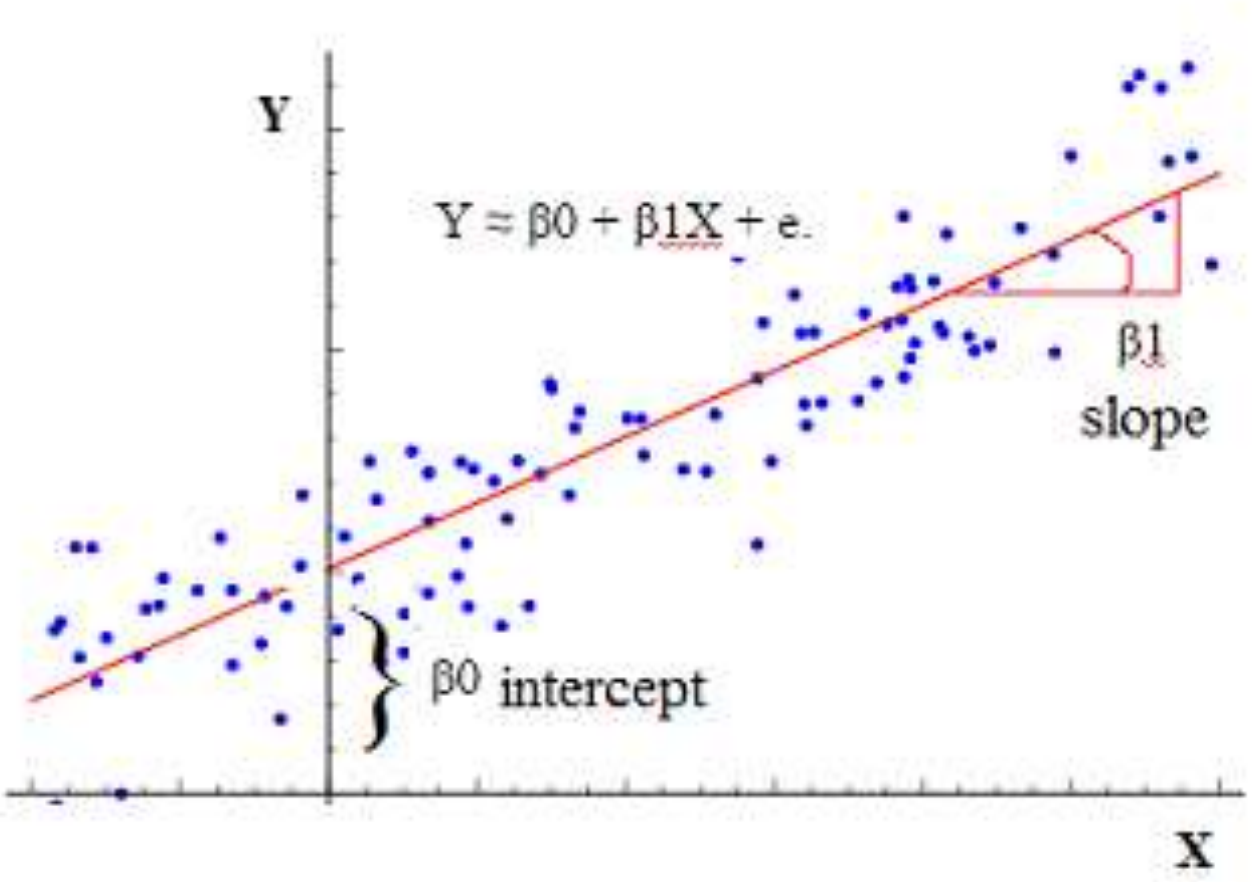
- 迴歸分析(Regression Analysis)可以分為簡單迴歸(Simple Regression)和多元迴歸(Multiple Regression)；簡單迴歸是用來探討1個依變數和1個自變數的關係，複迴歸(多元迴歸)是用來探討1個依變數和多個自變數的關係，迴歸的表示式：

- 複迴歸表示式： $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \beta n Xn + \varepsilon$

  β_0為常數，β_1 ….. βn為迴歸係數，ε為誤差

- 線性迴歸分析的基本統計假設：線性關係(linear relationship)、常態性 (normality)、誤差項的獨立性 (independence)、誤差項的變異數相等 (homoscedasticity)

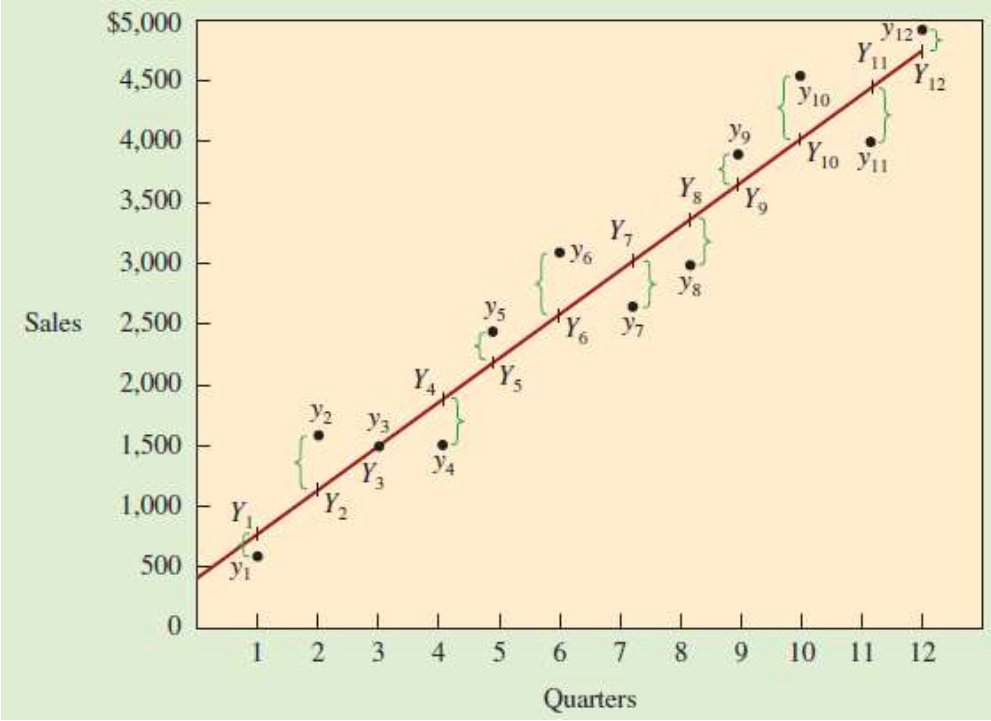
Simple Linear Regression (簡單線性迴歸)



Least Squares Method (最小平方法)

The least squares method determines the intercept and the slope such that the sum of the squared errors is minimized – “least squares”

Quarter	Sales		Quarter	Sales
1	600		7	2,600
2	1,550		8	2,900
3	1,500		9	3,800
4	1,500		10	4,500
5	2,400		11	4,000
6	3,100		12	4,900



$$Sum\ of\ squared\ errors$$
$$(y_1 - Y_1)^2 + (y_2 - Y_2)^2 + \cdots + (y_{12} - Y_{12})^2$$

Problem

Chicken Palace periodically offers carryout five-piece chicken dinners at special prices. Let Y be the number of dinners sold and X be the price. Based on the historical observations and calculations in the table, determine the regression equation, correlation coefficient, and coefficient of determination. How many dinners can Chicken Palace expect to sell at $3.00 each?

Observation	Price (X)	Dinners Sold (Y)
1	$2.70	760
2	$3.50	510
3	$2.00	980
4	$4.20	250
5	$3.10	320
6	$4.05	480
Total	$19.55	3,300
Average	$3.258	550

Solution

SOLUTION

We use the computer to calculate the best values of a, b, the correlation coefficient, and the coefficient of determination

$$a = 1{,}454.60$$
$$b = -277.63$$
$$r = -0.84$$
$$r^2 = 0.71$$

The regression line is

$$Y = a + bX = 1{,}454.60 - 277.63X$$

For an estimated sales price of $3.00 per dinner

$$Y = a + bX = 1{,}454.60 - 277.63(3.00)$$

$$= 621.71 \text{ or } 622 \text{ dinners}$$

F檢定迴歸模式的統計顯著

- 迴歸模式的顯著性檢定，一般都使用F test (檢定)，F 檢定將所有自變數計算進來，看應變數Y和所有自變數Xn是否有統計的顯著性。

F 檢定的虛無假設 (Null hyposesis) 如下：

H_0：$\beta 1 = \beta_2 \ldots\ldots = \beta n = 0$

H_1：Not all $\beta_i = 0$ (i = 1,2, …., n)

- 若F ＞ Fcrit ：顯著性存在，推翻虛無假設，需要作進一步解釋
- 若F ≦ Fcrit ：顯著性不存在，接受虛無假設 (查表可得F的臨界值)

- F值與自由度的計算公式如下：df= $(k-1, n-k)$

  F = (SSR regression / df regression) / (SSE total / df residual)

  df regression = (k-1)，k 為估計母數的數目, df residual = *n*-k，n為樣本數

調整前後的R平方係數

- 判定係數 R^2 (coefficient of determination) R^2是用來解釋線性迴歸模式的適配度 (goodness of fit)，$R^2 \neq 0$時，代表依變數(Y)被自變數 (X_n)所解釋的百分比率

- 在迴歸模式中，R^2會用來說明整個模式的解釋力，但是R^2受到樣本大小及*X*變數多寡的影響而呈現高估現象，因此，多數的學者都採用調整後的R^2 (使用的X變數越多會讓R^2呈現虛胖高估)

- 在迴歸模式具有統計顯著性後，想看看在迴歸方程式中，那些自變數(X_n)對依變數(Y)有較大的影響力，若原始資料尺度衡量不一致，例如：體重的公斤、公克，身高的公尺、公分，都會產生解釋迴歸變量的問題，因此，建議使用用標準化的係數。

- 由標準化的自變數所計算而得到的迴歸係數，我們稱為β係數 ，擁有β係數愈高的自變數(X_n)，對依變數(Y)的影響力愈大。

共線性問題

- 當自變數間X有共線性的問題時，代表自變數有共同解釋的部份，個別的自變數(Xi)，無法確認對依變數(Y)有多大的影響，那如何辨識自變數間有共線性的問題呢?
  - 步驟 1：查看相關係數，超過0.8就可能有共線性問題
  - 步驟 2：查看容忍值(tolerance)，容忍值 = (1- 自變數被其它變數所解釋的變異量)，容忍值(0~1之間)愈大愈好；容忍值的倒數 = 變異數膨脹因素 (VIF-variance inflation faction) ，VIF愈小愈好 (一般需<10)
- 當共線性發生時，可以忽略高相關性變數、只作預測, 不解釋迴歸係數或使用其它非線性迴歸分析來處理

RBI ~ AVG + OBP + SB + BB + HR, data = mlb

以AVG(打擊率)、OBP(上壘率)、SB(盜壘次數)、
BB(保送次數) 、HR(全壘打次數)預測RBI(打點)

	Coefficient	Significance
Intercept	-425.12	0.0018
AVG	4976.29	0.0089
OBP	-1955.97	0.35
SB	0.184	0.17
BB	0.509	0.062
HR	1.02	8.68x10^-9
P value	R^2	Adjusted
1.31x10^-12	0.92	0.91

整體迴歸模式顯著，重要的預測變數有AVG及HR

迴歸才能確定因果，相關係數不行

RBI=-425.12+4976*AVG-1955*OBP+0.184*SB+0.51*BB+1.02*HR

何謂虛擬(dummy)變數?

Y: 產出率, X: 三種機台 (M_1 , M_2 , M_3)

$$Y = a_0 + a_1 \times M_1 + a_2 \times M_2$$

M_1	1	0
M_2	0	1
M_3	0	0

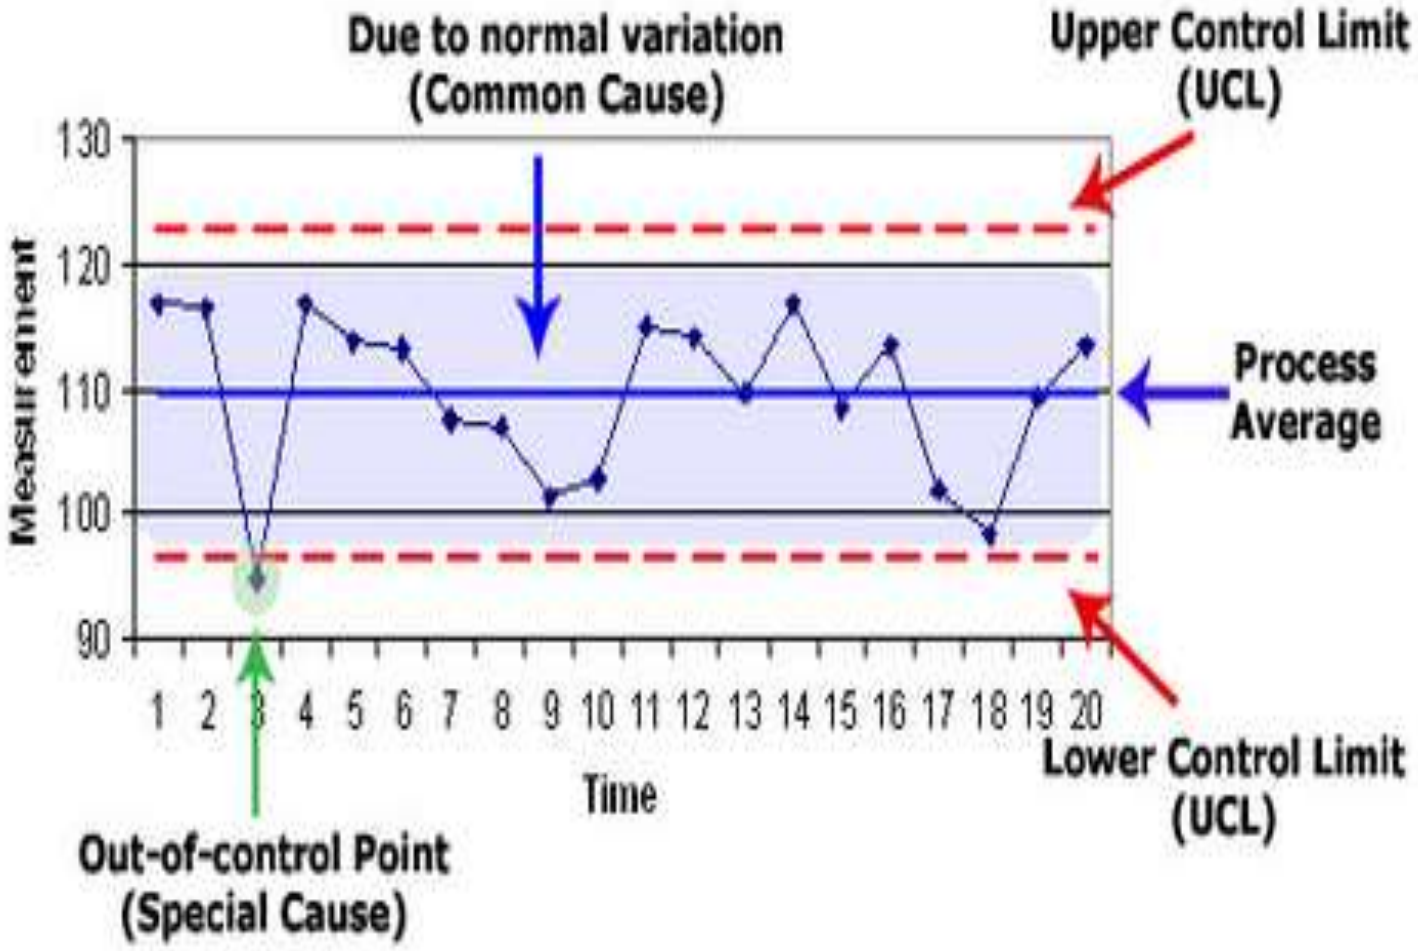
為何不使用$Y = a_0 + a_1 \times M_1 + a_2 \times M_2 + a_3 \times M_3$??

單變量統計分析

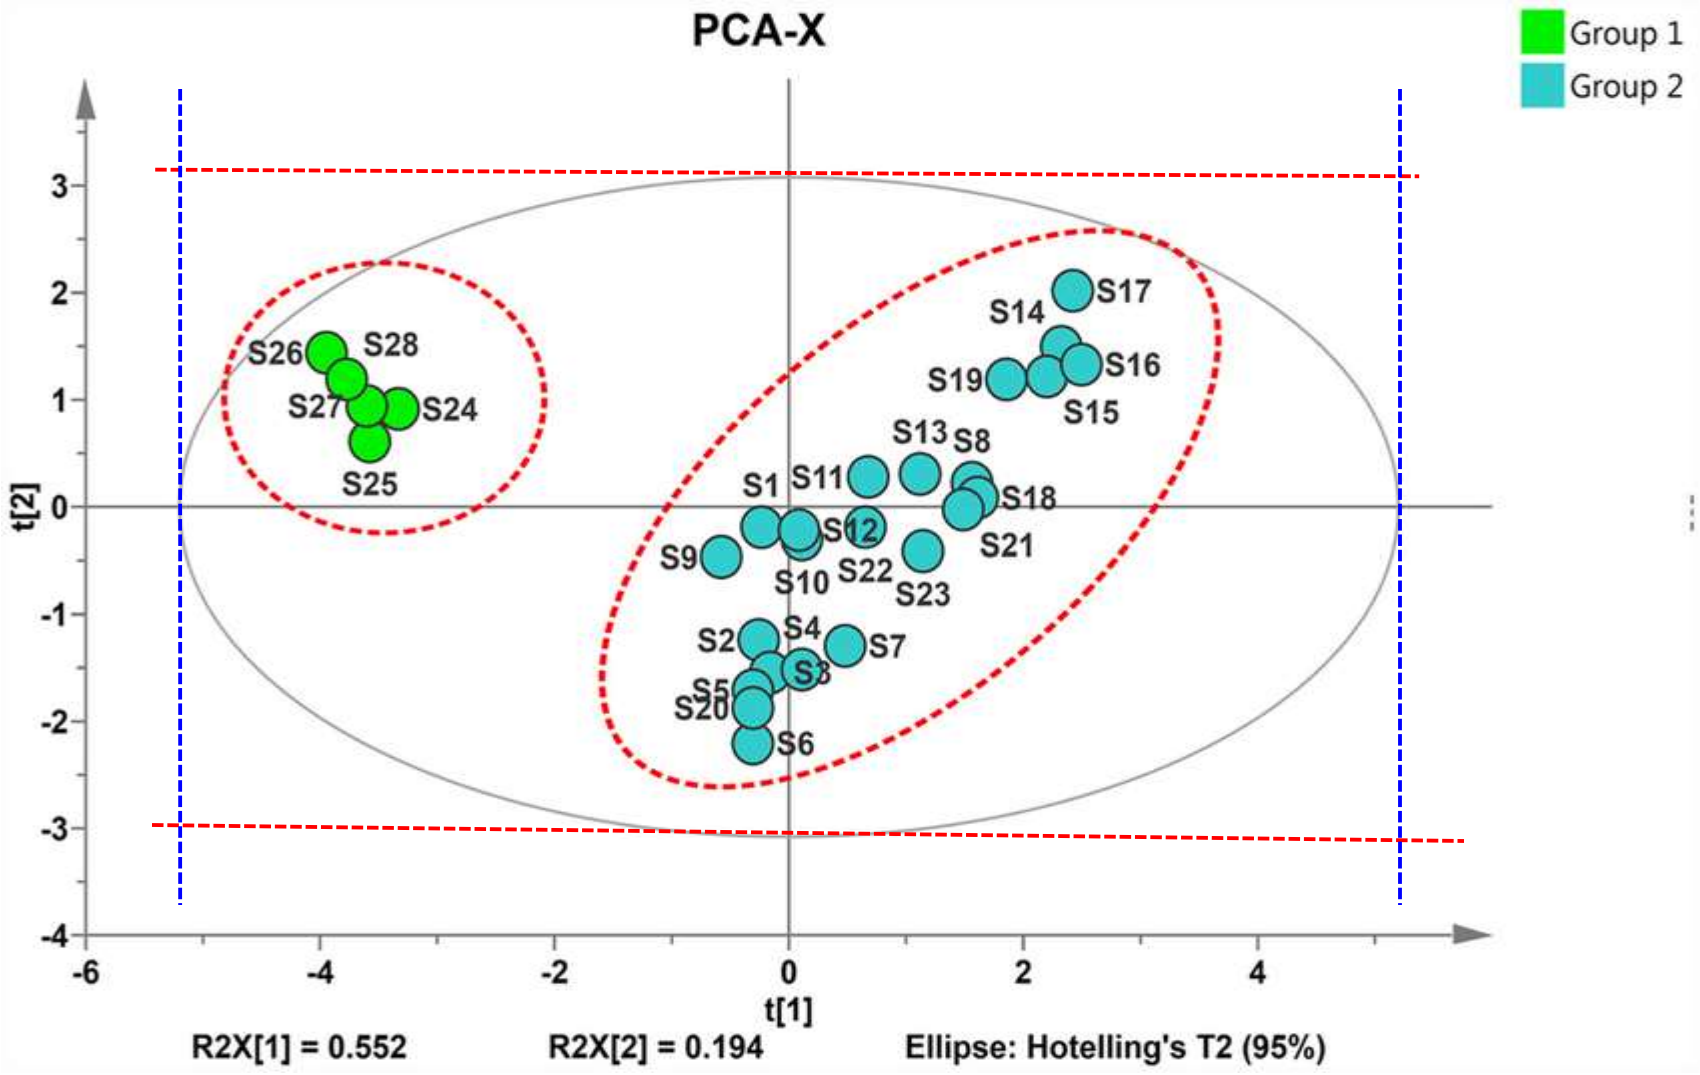
自變數X	依變數Y	分析方法
類別	類別	卡方交叉分析/比例檢定
類別	連續	ANOVA(變異數分析)
連續	連續	相關分析
連續	類別	T-test (平均值)/F-test(變異數)
類別/連續	連續	迴歸分析

若沒學過統計學的學員，請參考交大唐麗英老師開授的線上課程

Control chart (單變量管制圖)

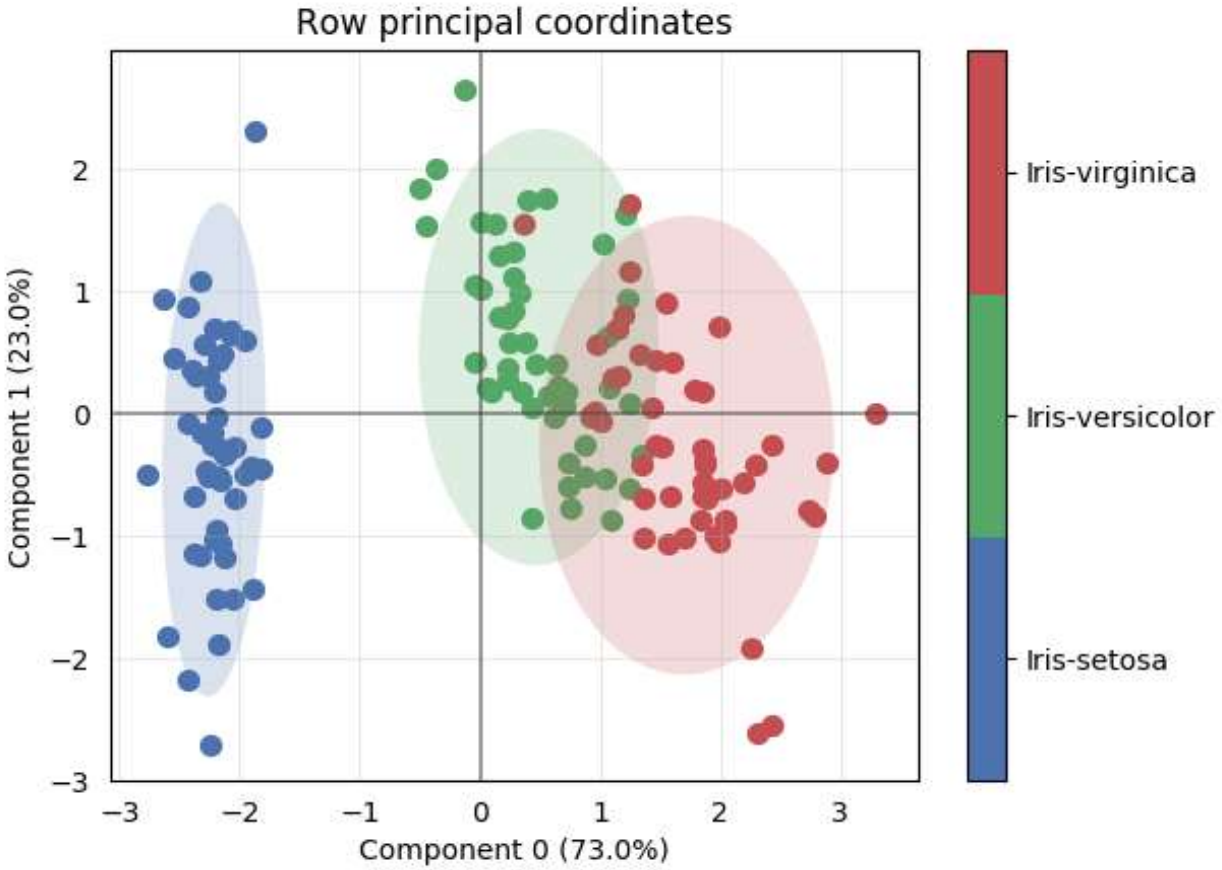


Control chart (多變量管制圖)

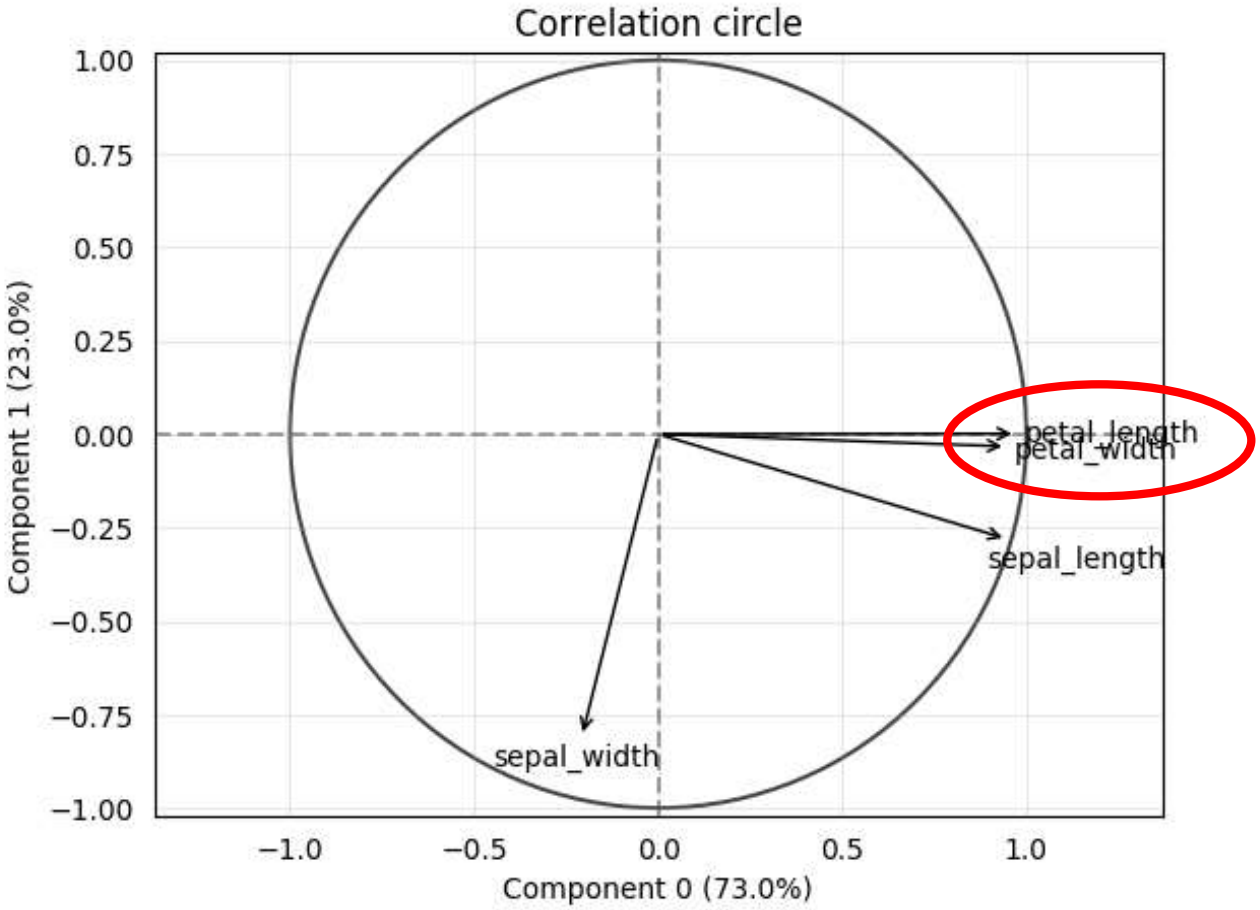


花卉資料集(花萼長寬、花瓣長寬)

四維降成2維



舊變數與新成份的對應


Correlation circle
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75
−1.00
Component 1 (23.0%)
−1.0
−0.5
0.0
0.5
1.0
Component 0 (73.0%)
petal_length
petal_width
sepal_length
sepal_width

多元尺度法(MDS) Multidimensional scaling

- Subjects
- Objects
- Attributes



price, quality, service, package, taste,…….

Introduction

- MDS was proposed by Torgerson in 1954 and then developed by Shephard et al.
- A dimension-reduction technique and a primary method to develop a perceptual map
- To analyze respondents' perceptions of objects
- It is often used in marketing to perform customer evaluations of products, services or brands.

Objectives of MDS

- Transforming consumer judgments of similarity or preference into the Euclidean distances which can be represented in a multi-dimensional space.
- Perceptual maps show the relative positioning of all objects and evaluation criteria.
- MDS can be also used to perform dimension reduction (from n dims to $2d$ or $3d$)

Stress Measure

- Kruskal's stress is a most commonly used measure for determining a model's goodness of fit
- The smaller the better

Stress	Fit
20%	Poor
10%	Fair
5%	Good
2.5%	Excellent
0%	Perfect

$$Stress = \left[\frac{\sum\sum_{i<j}(d_{ij}-\hat{d}_{ij})^2}{\sum\sum_{i<j}(d_{ij}-\bar{d}_{ij})^2}\right]^{\frac{1}{2}}$$

d_{ij} : Original distances

$\hat{d}_{ij}$: Distances on perceptual map

$\bar{d}_{ij}$: Average distance on perceptual map

主成份分析的概念

- 若欲將變數減少成少數幾個互相獨立的線性組合變數，亦即潛在變量或成份，就必須使用主成份分析。
- 主成份分析法是考慮將資料中原有的p個變數做線性組合得到k個新成份。通常k比p小很多。
- 主成份分析法的另一項功能是能將彼此間具有高度相關的p個變數，經過線性組合後成為k個彼此間相關係數為0的新變數，此過程稱為特徵萃取（feature extraction）。
- 使經由線性組合而得到的成份之變異數為最大，使觀測值在這些成份上顯示出最大的個別差異來。

主成份分析的應用

- 主成份分析除了用來簡化變數間之關係外，可用來縮減某一組欲進行多變量分析之變數的數目。
- 主成份分析也可將各變數的原始分數轉為主成份分數，以供進一步的統計分析。
- 主成份分析還可用來建構多種具有不同衡量單位變數之綜合指標。
- 主成份亦可根據其負荷量來對主成份命名。
- 例如：以身高與體重來建構「身材塊頭」指標、以成長率與佔有率來建構「市場行銷」指標。

主成份的萃取

- 假設有p個數字變數，則可計算出p個主成份。

$$Y_j = a_{j1}X_1 + a_{j2}X_2 + \ldots + a_{jp}X_p \qquad j = 1,2,\ldots, p$$

- 共同性會等於1，亦即沒有誤差項，故此公式不寫出誤差項。
- 主成份分析重視的是「變異數」，因素分析重視的則是「共變異數」。為使變異數達到最大，通常進行主成份分析後不再轉軸，因素分析則需要轉軸。
- 主成份分析使觀察值在這些主成份顯示出最大的個別變異，因素分析的目的是找出變數間的共同性。
- 因素分析: 例如想了解產品熱銷的原因，依據TAM分成有用性(usefulness)與易用性(ease of use)兩因子

主成份的萃取原理

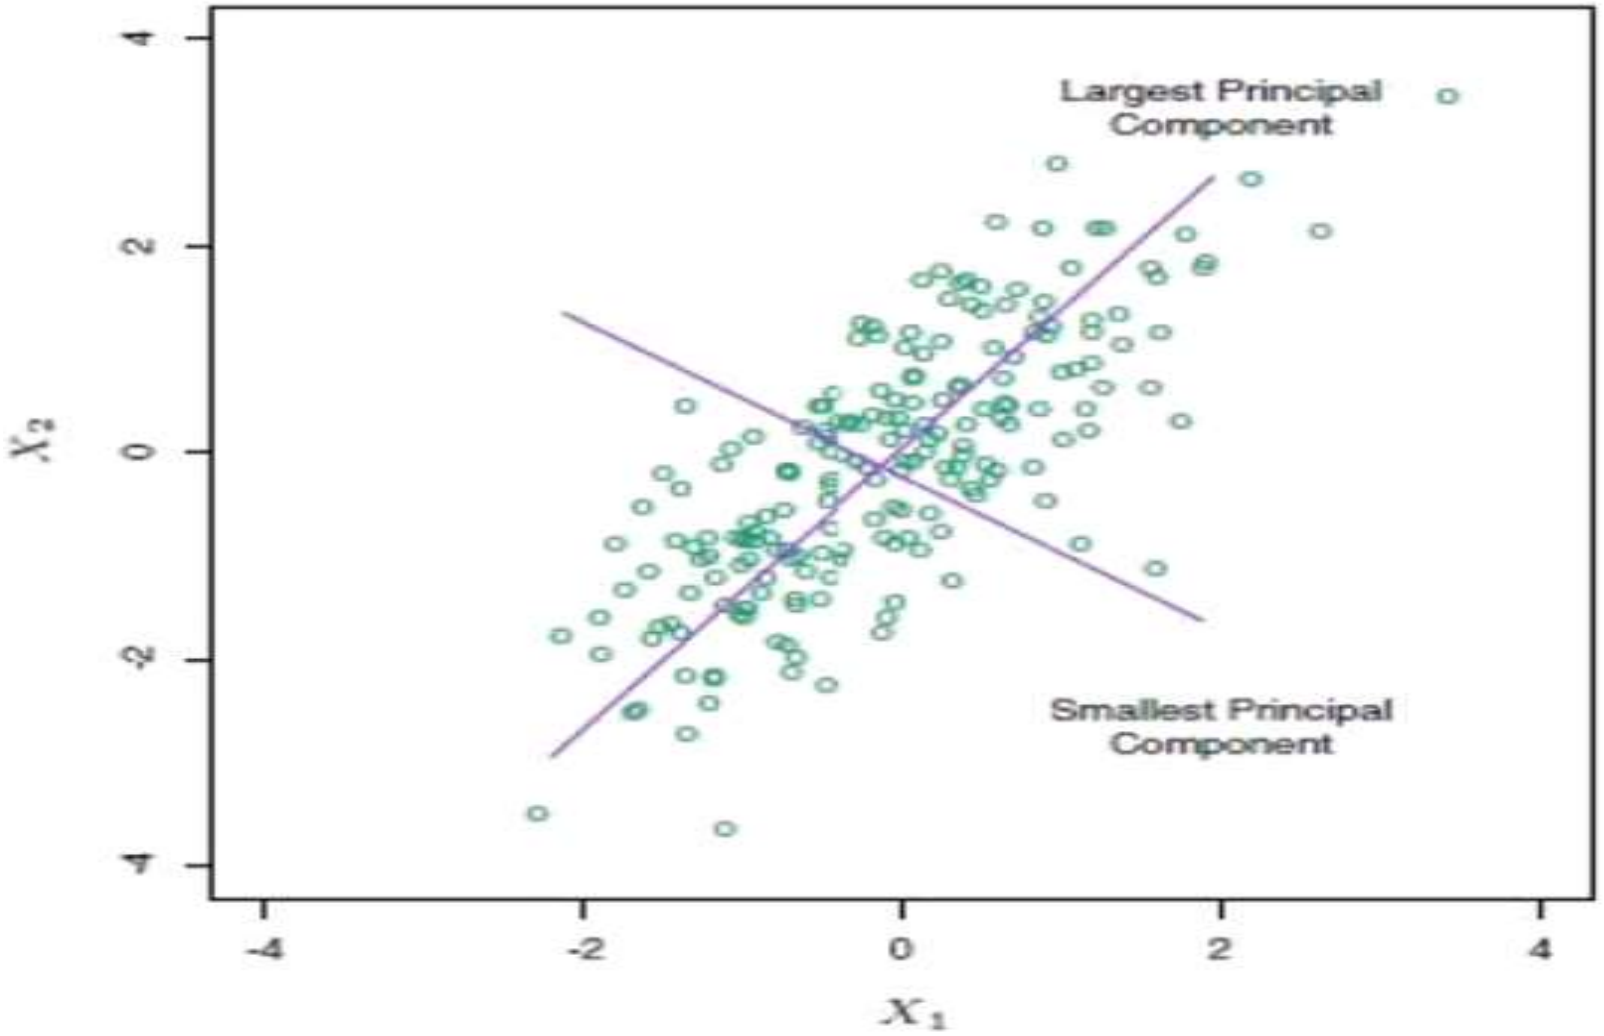
- 使組合 $y = a_1 x_1 + a_2 x_2 + \ldots + a_p x_p$ 在 $a'a = 1$ 下，Var(y)=$a'\Sigma a$最大的解a，正是共變數矩陣Σ的最大特徵值(eigenvalue)所對應的特徵向量(eigenvector)

- 最大特徵值所對應的特徵向量a是使Var(y)=$a'\Sigma a$最大的解。

- 假設本範例有身高與體重兩變數，為了提高每位學生的分辨能力，要使線性組合 $y_1 = a_1 x_1 + a_2 x_2$ 的變異數愈大愈好。在 $a_1^2 + a_2^2 = 1$ 的限制下，找 a_1, a_2值使 Var(y1) 最大。

- 主成份分析可使用共變異數矩陣，亦可使用或相關係數矩陣進行分析，一般當單位不同時以使用相關係數矩陣較佳。

舊變數與新成份的視覺化



主成份的特點

- 直交性(主成份彼此間直交獨立)
- 特徵值就是主成份的變異數 $Var(y_j) = \lambda_j$
- 所有主成份的變異數總和與所有變數之變異數總 和相等

$$\sum_{j=1}^{p} Var(y_j) = \sum_{i=1}^{p} Var(x_i)$$

- 主成份解釋的變異數比例

$$\frac{Var(y_j)}{\sum_{j=1}^{p} Var(y_j)} = \frac{Var(y_j)}{\sum_{i=1}^{p} Var(x_i)} = \frac{\lambda_j}{\sum_{i=1}^{p} \lambda_i}$$

- 主成份負荷(loading)- 相關係數 $r_{y_j x_i} = \frac{a_{ji}\sqrt{\lambda_j}}{s_i}$

$r^2_{y_1 x_1} = h^2_{11} = 0.952^2 = 0.907$ (第一主成分解釋身高的比例)

$r^2_{y_2 x_1} = h^2_{21} = 0.305^2 = 0.093$ (第二主成分解釋身高的比例)

- 共同性(Communality, h^2) $\sum_{i=1}^{p} h^2_{ji} = h^2_{j1} + h^2_{j2} + \ldots\ldots + h^2_{jp} = h^2_j = \lambda_j$
- 主成份分數(Score)- 讓舊變數轉換成新座標(在新成份的投影)

主成份的計算

- 經過主成份萃取後已可得到每個主成份下每個變數的係數（權重），如此就可得到每筆資料經過主成份轉換後的主成份分數。
- 變數萃取後的分析將不再使用原始變數，而是使用綜合指標的主成份。至於要如何計算每一筆資料的主成份分數呢？ R將會自動幫您計算。
- 第i個資料 $(x_{1i}, x_{2i}, .., x_{pi})$ 的第j個主成份，其中 $\bar{x}_i$ 為第i個變數的平均數，即：

$$y_{ji} = a_{j1}(x_{1i} - \bar{x}_1) + a_{j2}(x_{2i} - \bar{x}_2) + \cdots + a_{jp}(x_{pi} - \bar{x}_p)$$

如第1位學生在第一個主成份的分數為：

係數已標準化：0.707(-1.815-0)+0.707(-1.320-0)=-2.216

IC_design 資料集

Financial Perceptive	A1	Debt ratio
	A2	Current ratio
	A3	Quick ratio
	A4	Turnover rate of accounts receivable
	A5	Turnover rate of inventory
	A6	Turnover rate of fixed assets
	A7	Ratio of cash flow
	A8	Product sale revenue
	A9	Turnover rate of total assets
	A10	Days of inventory turn
Learning & Growth	B1	Number of employees
	B2	Turnover rate of employees
	B3	Average working years of employees
	B4	Average age of employees
	B5	Patent item
Customer	C1	Product varieties
	C2	Profit margin of major products
	C3	Proportion of major products
	C4	Export ratio of major products
Internal process	D1	Ratio of employees' stock bonus
	D2	Ratio of R&D investment
	D3	Ratio of operational expense
	D4	Growth rate of revenues
	D5	Operational efficiency

PCA轉軸

```
> library(psych)
> a=cor(ALL1)
> pc <- principal(a,8,rotate= “varimax” ) #最大變異法
> pc
```

```
Principal Components Analysis
Call: principal(r = a, nfactors = 8, rotate = "varimax")
Standardized loadings (pattern matrix) based upon correlation matrix
```

	RC1	RC2	RC3	RC5	RC4
A1	0.86	0.11	-0.06	0.01	0.01
A2	0.90	-0.15	0.06	-0.19	-0.05
A3	0.91	-0.12	0.09	-0.13	-0.05
A4	-0.17	0.33	0.10	0.09	-0.04
A5	-0.14	0.06	-0.08	0.79	-0.02
A6	-0.04	-0.04	-0.05	-0.13	0.82
A7	0.12	-0.02	-0.71	0.21	-0.11
A8	-0.12	0.91	-0.04	0.07	0.00
A9	-0.57	-0.05	-0.29	0.32	0.27
A10	0.13	-0.08	0.16	-0.87	0.09
B1	-0.11	0.90	0.02	-0.01	-0.09
B2	-0.14	-0.19	0.57	0.33	-0.11
B3	0.24	-0.22	-0.14	-0.52	0.52
B4	0.13	-0.14	-0.09	0.22	0.14
B5	-0.23	0.80	0.07	0.00	-0.08
C1	-0.14	0.11	0.26	-0.08	-0.37
C2	0.26	0.05	0.01	-0.16	-0.01
C3	0.12	0.08	0.29	0.15	0.26
C4	0.00	0.16	-0.06	-0.01	-0.15
D1	0.06	0.68	-0.06	0.10	0.09
D2	0.33	0.03	0.82	-0.07	-0.12
D3	0.35	-0.01	0.80	-0.13	-0.15
D4	-0.20	0.01	-0.32	0.34	0.35
D5	-0.18	-0.14	-0.37	0.00	0.56

最大變異法：
使每一個問項只會對一個因素產生極大的因素負荷量，避免重複解釋的困擾。

RC1 :A1,A2,A3,A9,C2 => 短期還債能力

RC2 : A4,A8,B1,B5,C4,D1 => 員工收益

RC3 : A7,B2,C1,D2,D3 => 研究發展

RC4 : A6,B3,B4,D5 => 公司情況

RC5 : A5,A10,C3,D4=> 商品收益

	RC1	RC2	RC3	RC5	RC4	RC7	RC8	RC6
SS loadings	3.37	3.09	2.70	2.22	1.79	1.66	1.56	1.37
Proportion Var	0.14	0.13	0.11	0.09	0.07	0.07	0.06	0.06
Cumulative Var	0.14	0.27	0.38	0.47	0.55	0.62	0.68	0.74
Proportion Explained	0.19	0.17	0.15	0.13	0.10	0.09	0.09	0.08
Cumulative Proportion	0.19	0.36	0.52	0.64	0.74	0.84	0.92	1.00

主成分分數

獲取主成分得分的係數

	RC1	RC2	RC3	RC5	RC4
A1	-0.34	-0.08	0.02	-0.12	-0.06
A2	0.31	0.03	-0.06	0.02	0.03
A3	0.32	0.04	-0.05	0.06	0.03
A4	-0.10	0.01	0.01	0.04	-0.06
A5	0.06	-0.01	0.00	0.39	-0.07
A6	0.01	0.03	0.06	-0.14	0.55
A7	0.11	-0.02	-0.32	0.12	-0.17
A8	0.07	0.34	-0.02	0.00	0.02
A9	-0.12	-0.03	-0.02	0.07	0.08
A10	-0.08	0.00	0.03	-0.45	0.14
B1	0.03	0.31	-0.01	-0.03	-0.03
B2	-0.06	-0.11	0.26	0.20	-0.09
B3	-0.03	-0.08	-0.16	-0.22	-0.29
B4	0.05	-0.03	-0.04	0.05	0.20
B5	-0.05	0.24	0.02	-0.05	0.00
C1	-0.10	0.04	0.05	-0.09	-0.10
C2	-0.02	-0.09	-0.10	-0.05	0.00
C3	0.01	-0.06	0.07	0.05	0.20
C4	0.00	0.00	-0.11	-0.06	-0.07
D1	0.13	0.29	-0.01	0.03	0.10
D2	0.04	0.02	0.32	0.06	0.03
D3	0.03	0.00	0.30	0.03	0.02
D4	-0.04	-0.04	-0.09	0.11	0.18
D5	0.03	0.01	-0.06	-0.05	0.26

第一主成分方程式：

Y1= -0.34A1+0.31A2+0.32A3+…+
0.03D3-0.04D4+0.03D5

第二主成分方程式：

Y2= -0.08A1+0.03A2+0.04A3+…+
0D3-0.04D4+0.01D5

⋮

第五主成分方程式：

Y5= -0.06A1+0.03A2+0.03A3+…+
0.02D3+0.18D4+0.26D5

新的資料座標

由原本的24個維度降低為5個維度，共508筆資料。

	pc1	pc2	pc3	pc4	pc5
1	-0.294008255	-0.11913475	-0.15029836	-0.2069387162	-0.029575927
2	-0.218188141	-0.18363269	-0.03950108	0.2371525564	0.162221027
3	-0.012725966	-0.06068447	-0.41056255	0.0915402756	-0.102323884
4	0.018024457	-0.14387228	-0.37732842	-0.0242736848	0.404195227
5	0.062015125	-0.12964926	-0.41561931	0.1063757810	0.283378175
6	-0.099222233	-0.03422239	-0.34022708	0.1939449733	0.243249126
7	-0.015207267	-0.12926542	-0.31960406	0.1958770845	0.056247480
8	0.040410782	-0.25868912	-0.38804797	0.5223989441	0.131165759
9	0.303425618	-0.25234849	-0.60211220	0.0664960795	0.222977309
10	-0.142152928	-0.16605878	-0.31072748	0.1402929978	0.403229435
11	-0.010220474	-0.16625444	-0.48084297	-0.0555894144	0.043588455
12	0.099788012	-0.18497549	-0.49267462	0.1282341322	0.581081169
13	-0.085000517	-0.12057194	-0.39158252	0.0884719163	0.298164701
14	-0.064902053	-0.19682856	-0.24737583	0.1785432887	0.306997436
15	0.051787227	-0.17086289	-0.51085836	0.0118103590	0.367919144
16	-0.031504991	-0.15633585	-0.44198018	-0.0827678741	0.447400691
17	0.092072125	-0.18468440	-0.37170763	0.2577709010	0.233853419
18	-0.019454626	-0.15370042	-0.44806317	0.0548869360	0.399724939
19	0.055054842	-0.18298488	-0.28015666	0.3244204553	0.416575831
20	0.253861233	-0.13127213	-0.38159869	0.2299782038	0.324294202
21	0.278509509	-0.11530537	-0.36433545	0.0951178961	0.645541324
22	-0.281513652	-0.11810840	-0.15170602	-0.2091329406	-0.011835295
23	-0.187251975	-0.18521224	-0.04523172	0.2308649694	0.133195652
24	-0.034793822	-0.08444138	-0.38126666	0.0608671774	-0.066692578
25	-0.031658724	-0.16482552	-0.38319051	-0.0006543543	0.530654837
26	0.082714890	-0.12423682	-0.44388096	0.1012160237	0.288463355